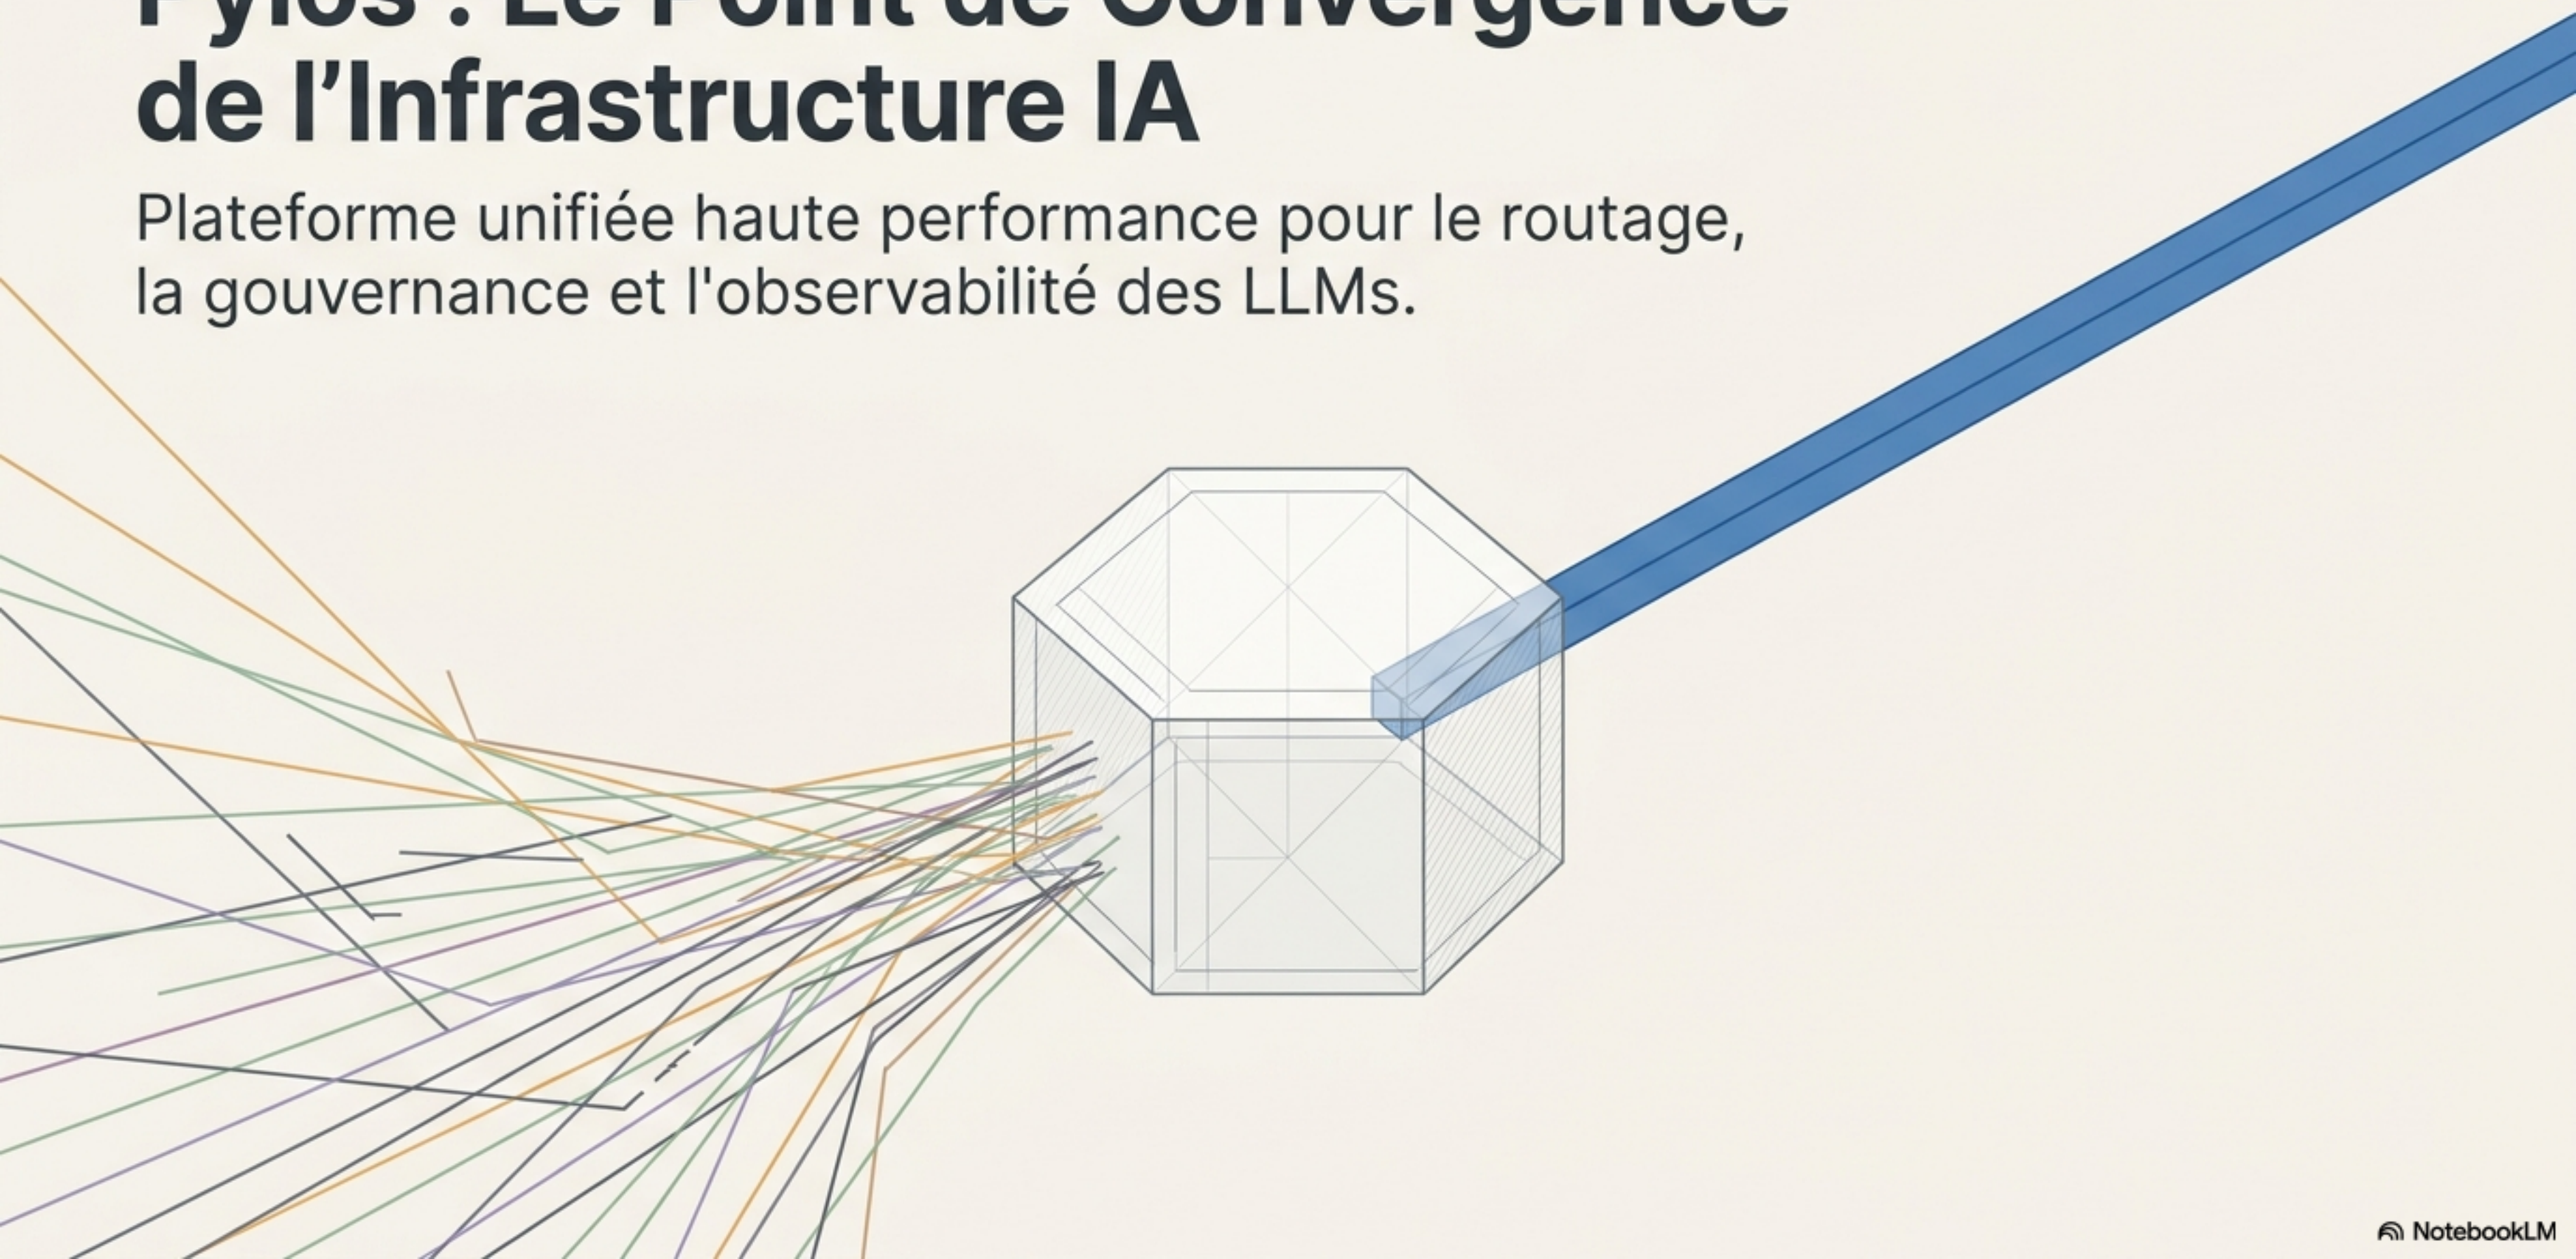
Pylos : Le Point de Convergence de l’Infrastructure IA

Plateforme unifiée haute performance pour le routage, la gouvernance et l'observabilité des LLMs.



NotebookLM

L’adoption sans friction : Compatibilité native OpenAI



100% Transparent

Support complet des endpoints /v1/chat/completions, /embeddings et /images/generations.

Avant

```
base_url = "https://api.openai.com/v1"
api_key = "sk-12345..."
```

Avec Pylos

```
base_url = "https://pylos.votre-domaine.com/v1"
api_key = "sk-pylos-12345..."
```



Clés Virtuelles

Utilisation d'un format sécurisé **sk-pylos-*** qui masque la complexité sous-jacente.



Drop-in Replacement

Fonctionne instantanément avec les SDK Python et Node.js existants sans modifier la logique applicative.

NotebookLM

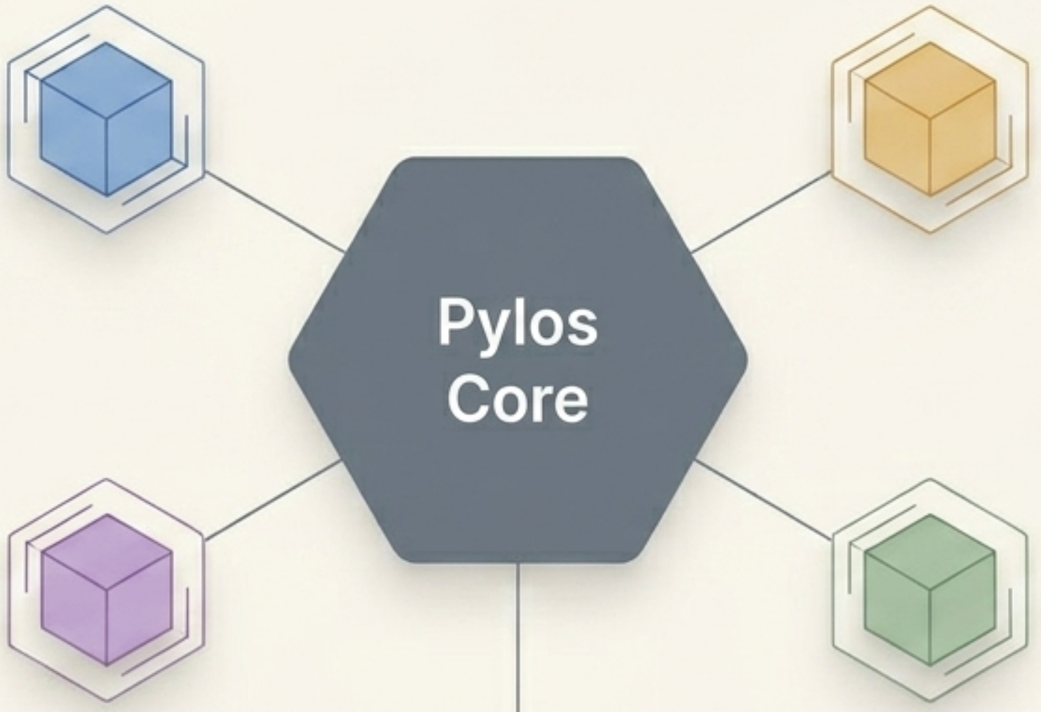
Le Prisme de Contrôle : Anatomie d'une Gateway IA

Connecter (Routage & Fournisseurs)

Unifier plus de 20 fournisseurs d'IA derrière 6 adaptateurs natifs avec load-balancing.

Sécuriser (Gouvernance & Accès)

Protéger les ressources via des clés virtuelles, budgets stricts et RBAC granulaire.



Étendre (Plugins & MCP)

Enrichir les requêtes via un pipeline de Pre/Post-hooks (RAG, Cache, Guardrails).

Observer (Télémétrie & UI)

Auditer chaque token via OpenTelemetry, Prometheus et un Command Center React.

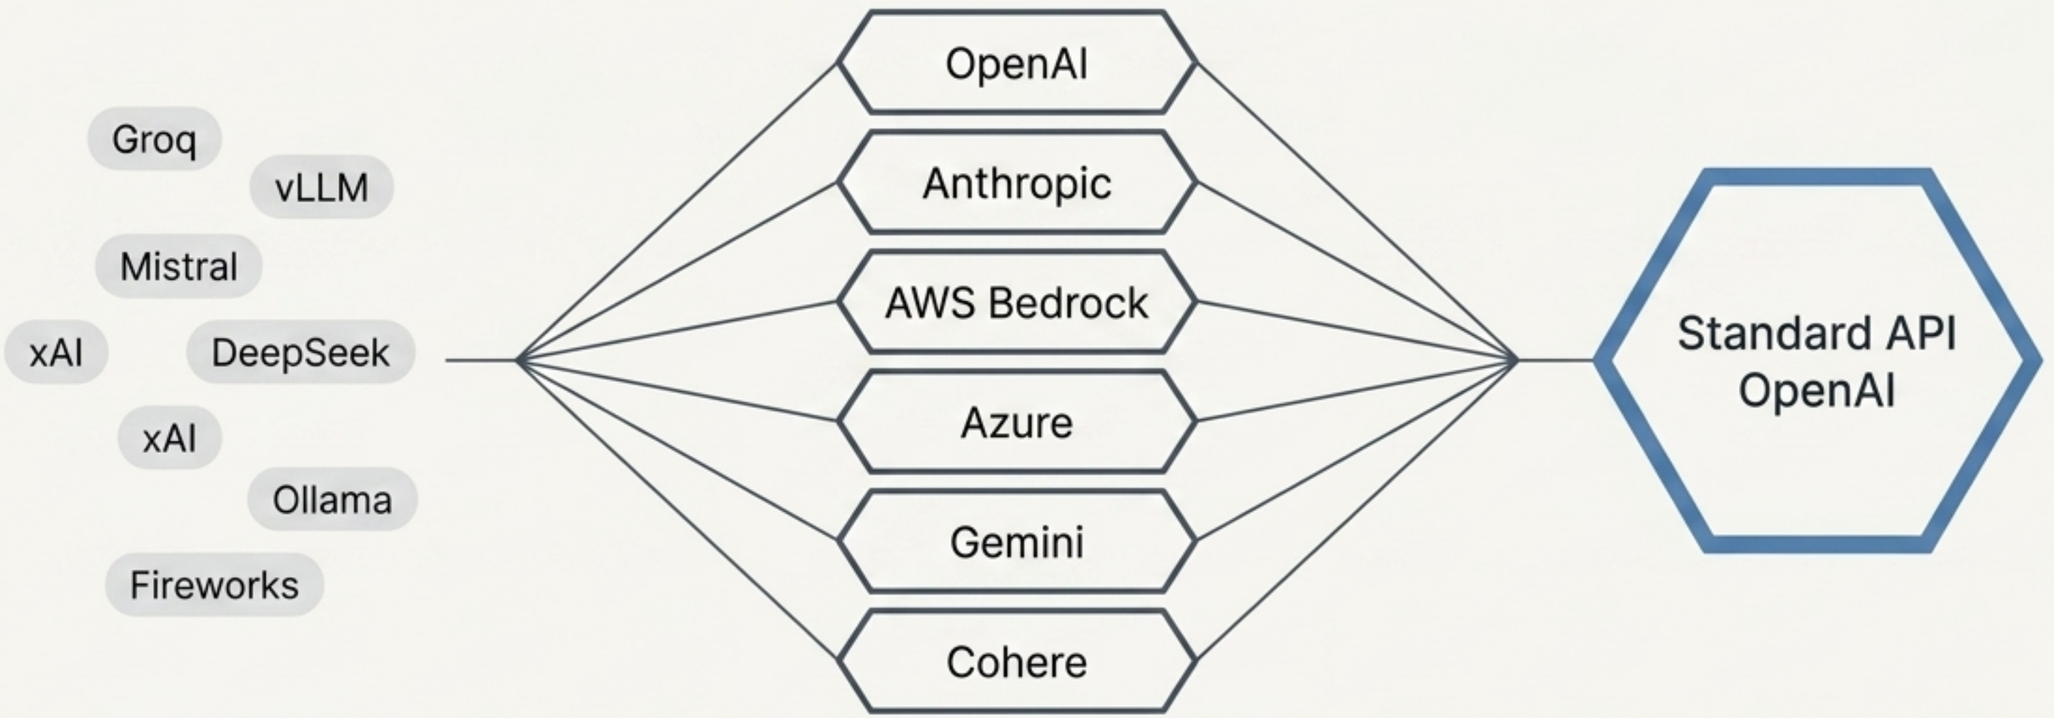
Fondation Rust

Architecture hexagonale en Rust, ultra-faible latence, déploiement Docker/K8s natif.

NotebookLM

Premium architectural whitepaper

Du Chaos à l'Unification : 20+ Modèles, 1 Interface



Auto-Détection

Routage automatique basé sur la syntaxe (ex: `gpt-*` vers OpenAI, `claude-*` vers Anthropic).

Streaming Natif

Support intégral SSE, Tool Calls en streaming, et Reasoning Content (DeepSeek R1, OpenAI o1).

Model Mapping

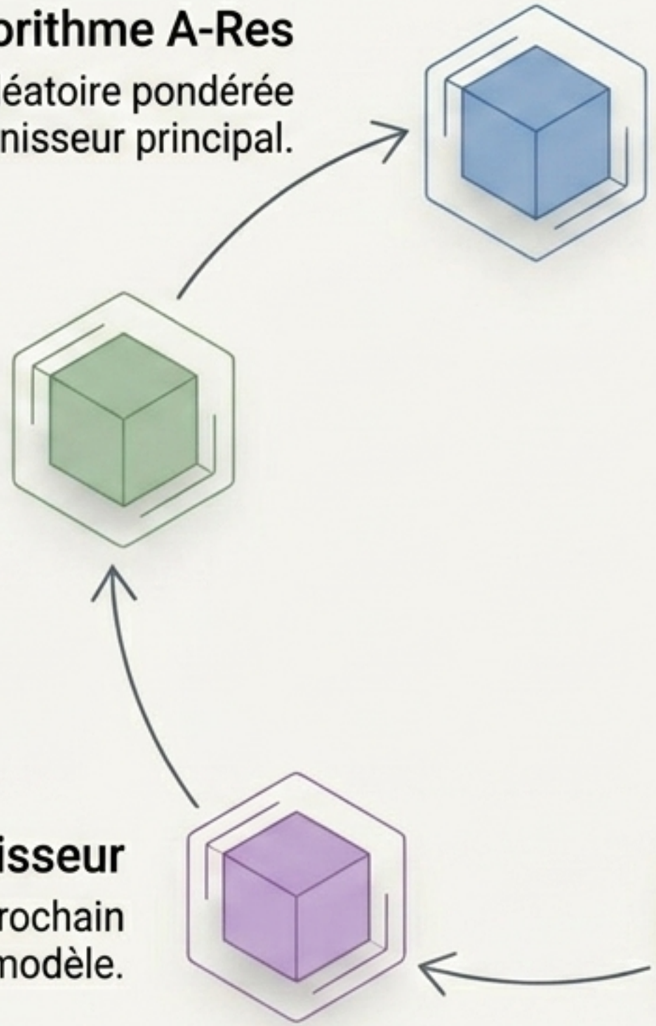
Traduction dynamique à la volée (ex: `gemini-2.5-flash` vers `deepseek-v4-flash`).

NotebookLM

Premium architectural whitepaper

Tolérance aux Pannes et Routage Intelligent

Moteur de règles CEL (Common Expression Language) permettant un routage A/B pondéré et dynamique sans interruption de service.



Algorithme A-Res

Sélection aléatoire pondérée vers le fournisseur principal.

Panne Détectée

Simulation ou timeout du fournisseur.

Circuit Breaker

5 échecs consécutifs = désactivation pendant 30 secondes.

Fallback Multi-Fournisseur

Routage dynamique vers le prochain meilleur fournisseur supportant le modèle.

Retry Exponential Backoff

Nouvelle tentative avec délai exponentiel et jitter garantissant le succès.

NotebookLM

Premium architectural whitepaper

Modèle de Sécurité Multicouche : Protection et Contrôle

Note : L'architecture in-memory des clés garantit un lookup ultra-rapide sans pénaliser la latence de l'API.

Périmètre Réseau

OIDC / JWT Validation (RS256 / HS256) & Authentification Admin à temps constant.

Limites Système

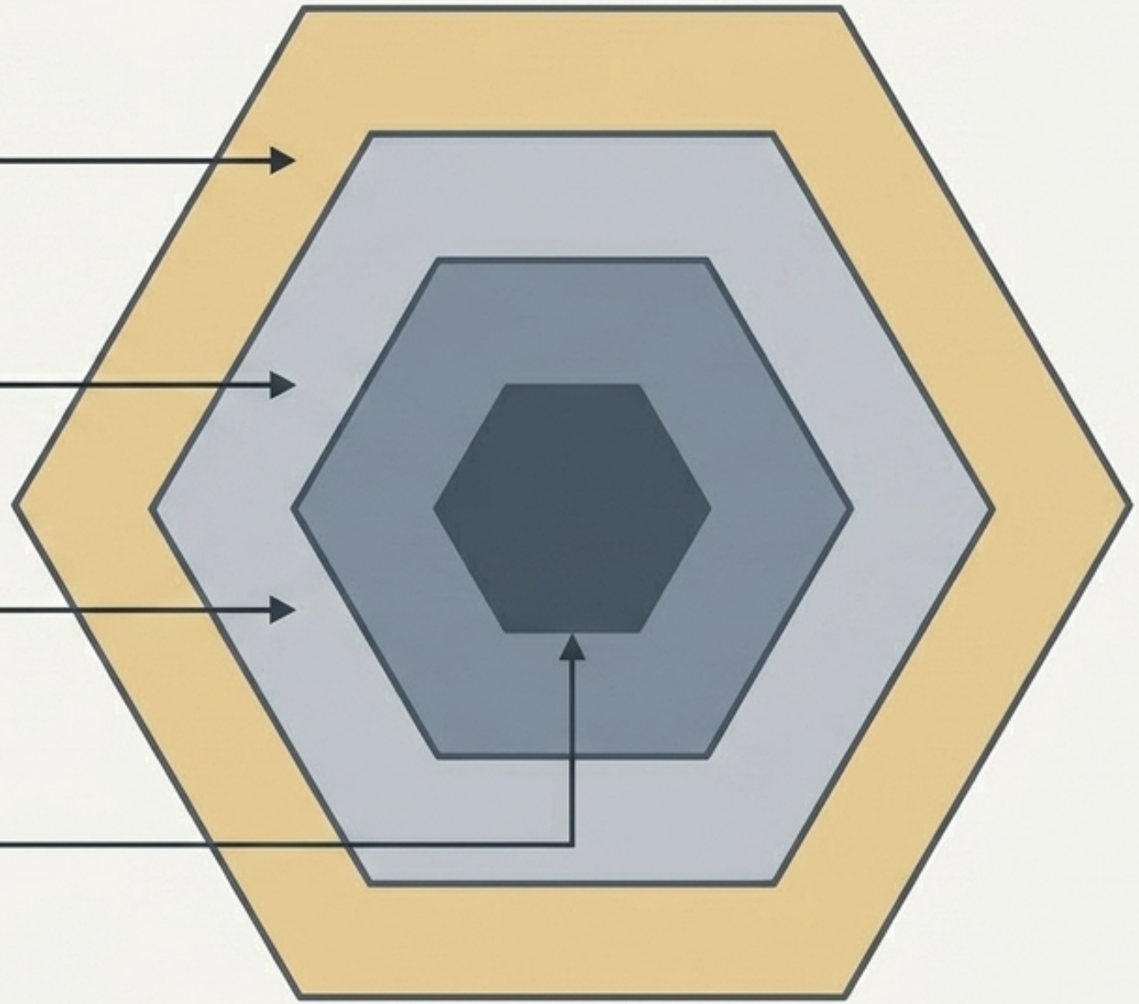
Atomic Rate Limiting (RPM/TPM) persisté sur SQLite/Postgres.

Contrôle Budgétaire

Enforcement des budgets en USD avec resets configurables (30s à 1 an).

Clé Virtuelle Pylos

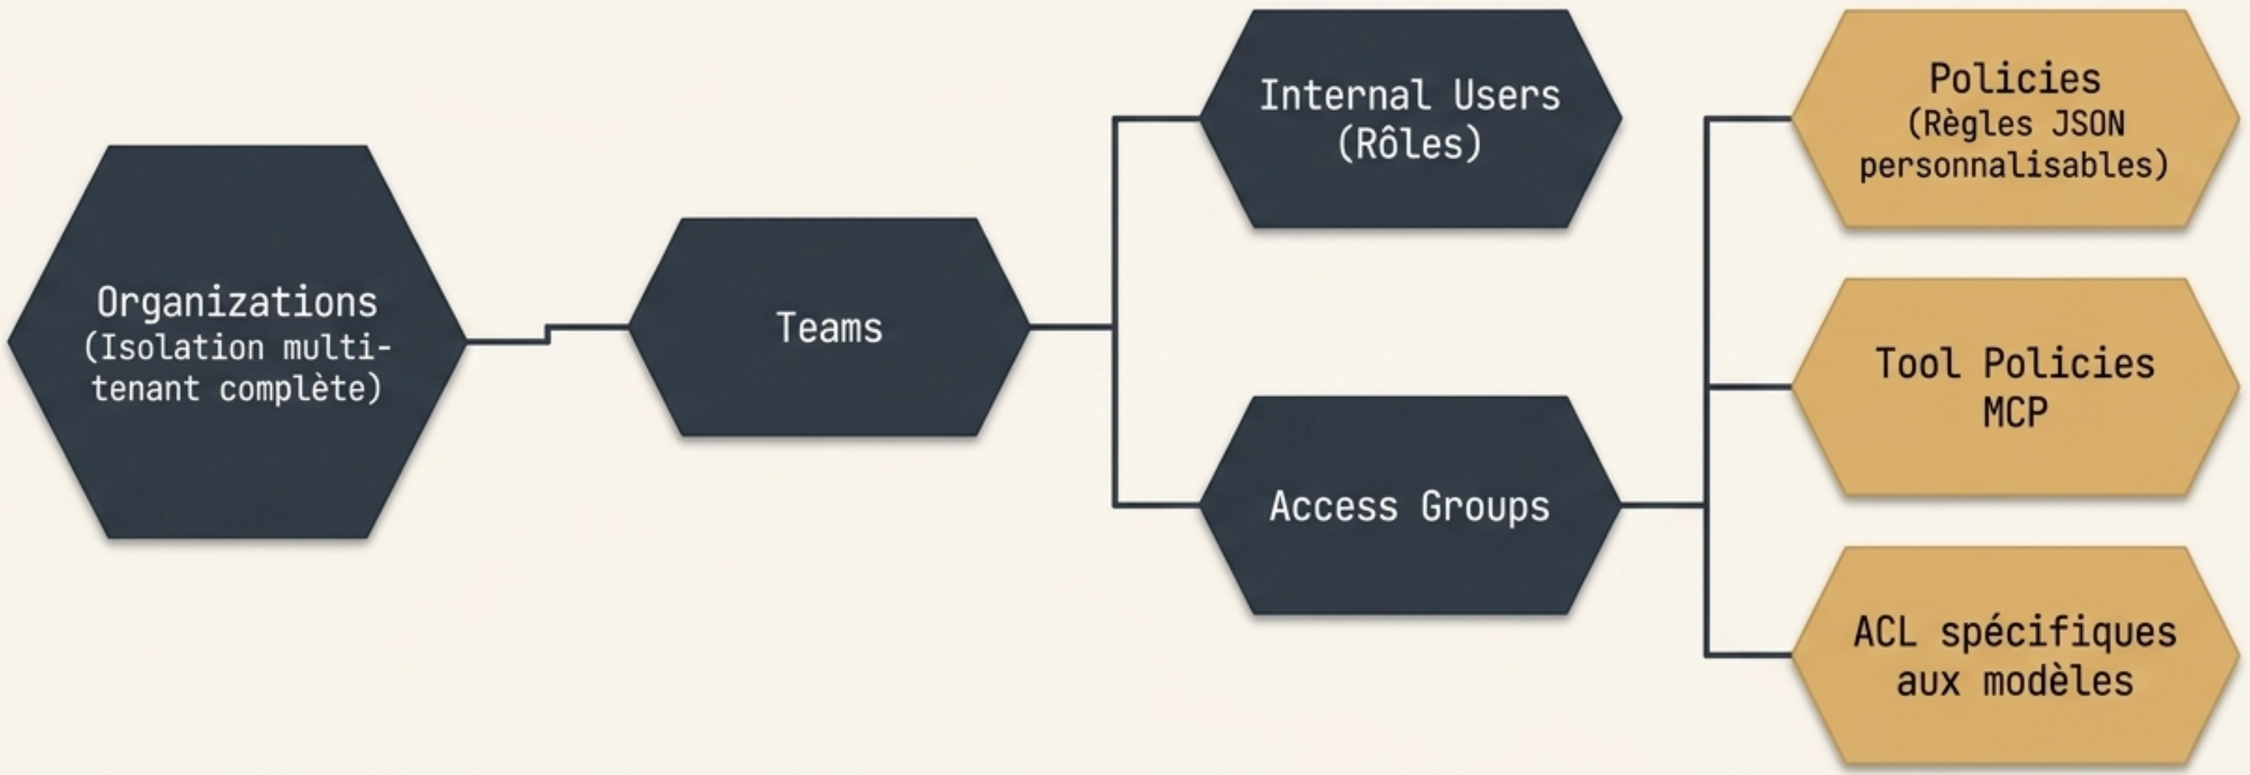
Clé in-memory `sk-pylos-*` avec ACL par fournisseur/modèle et date d'expiration.



NotebookLM

Topologie RBAC : Gouvernance Multi-Tenant

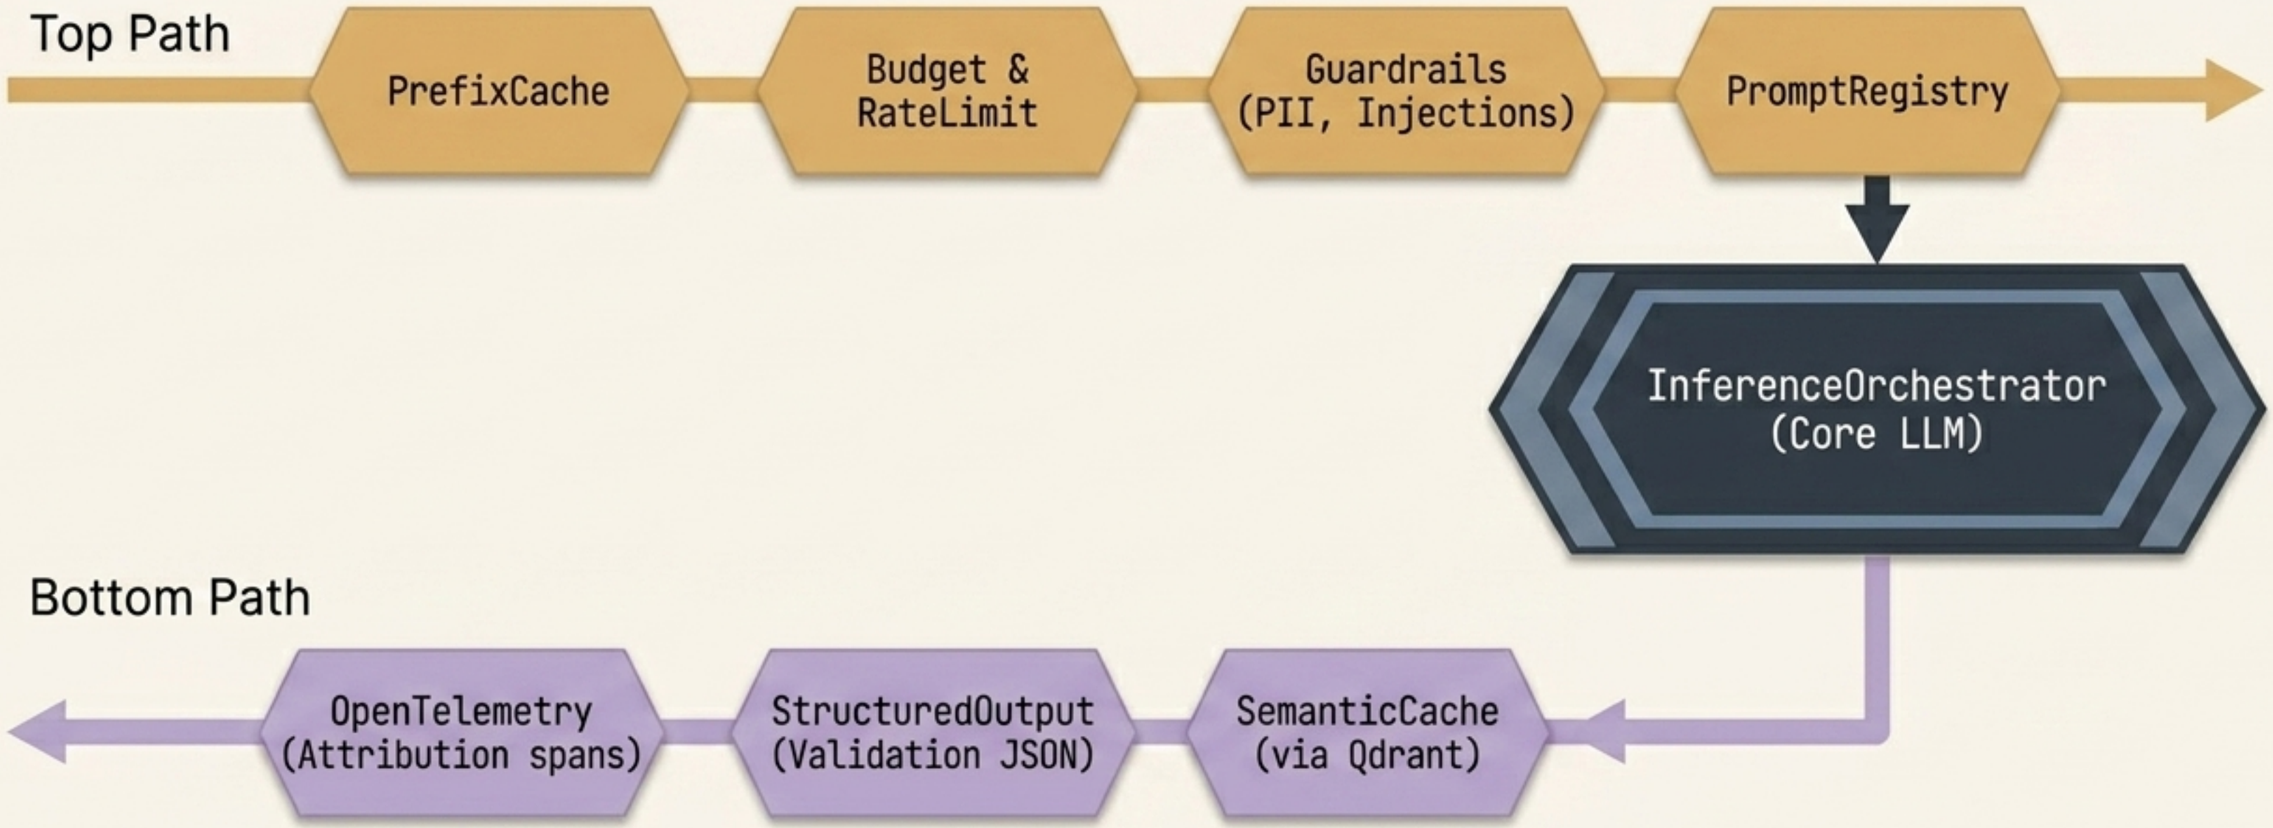
Une granularité d'accès totale permettant d'isoler les coûts, les permissions et les limites par projet, équipe ou utilisateur final, configurable via l'API Management.



NotebookLM

Architecture d’Extension : Le Pipeline Pre/Post-Hooks

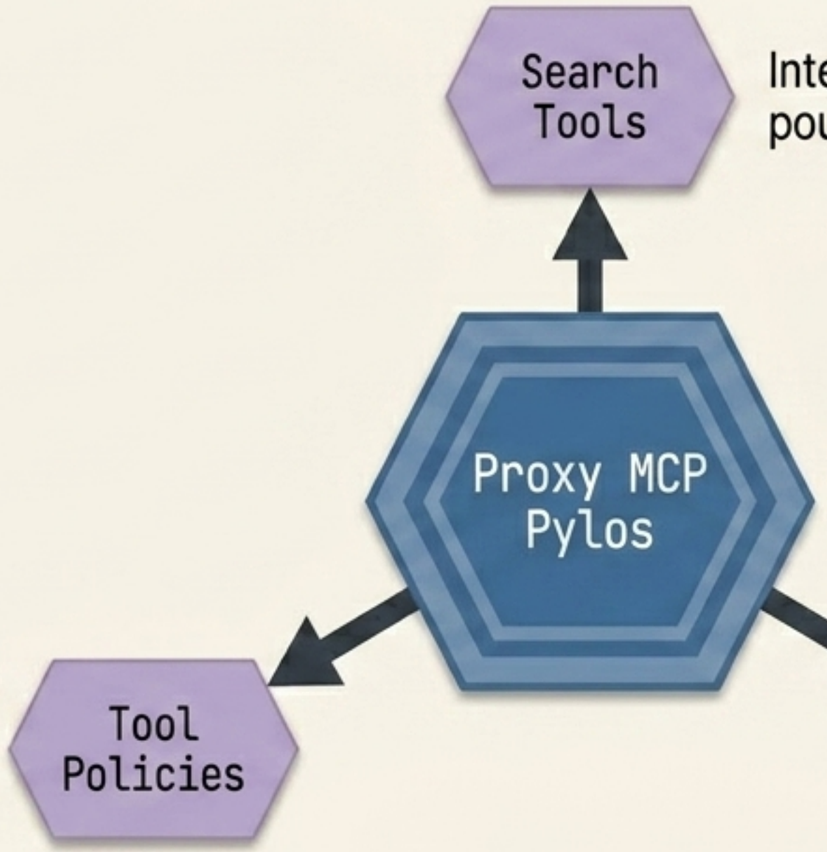
Un système d’interception à la volée qui sécurise, valide et met en cache les données sans modifier le code client.



NotebookLM

Proxy MCP (Model Context Protocol) : L'IA Agentique Sécurisée

Pylos ne se contente pas de router les requêtes ; il agit comme une interface unifiée pour exposer, gouverner et injecter des outils externes et des mémoires vectorielles (RAG) aux modèles LLM.



Interface de configuration pour la recherche externe.

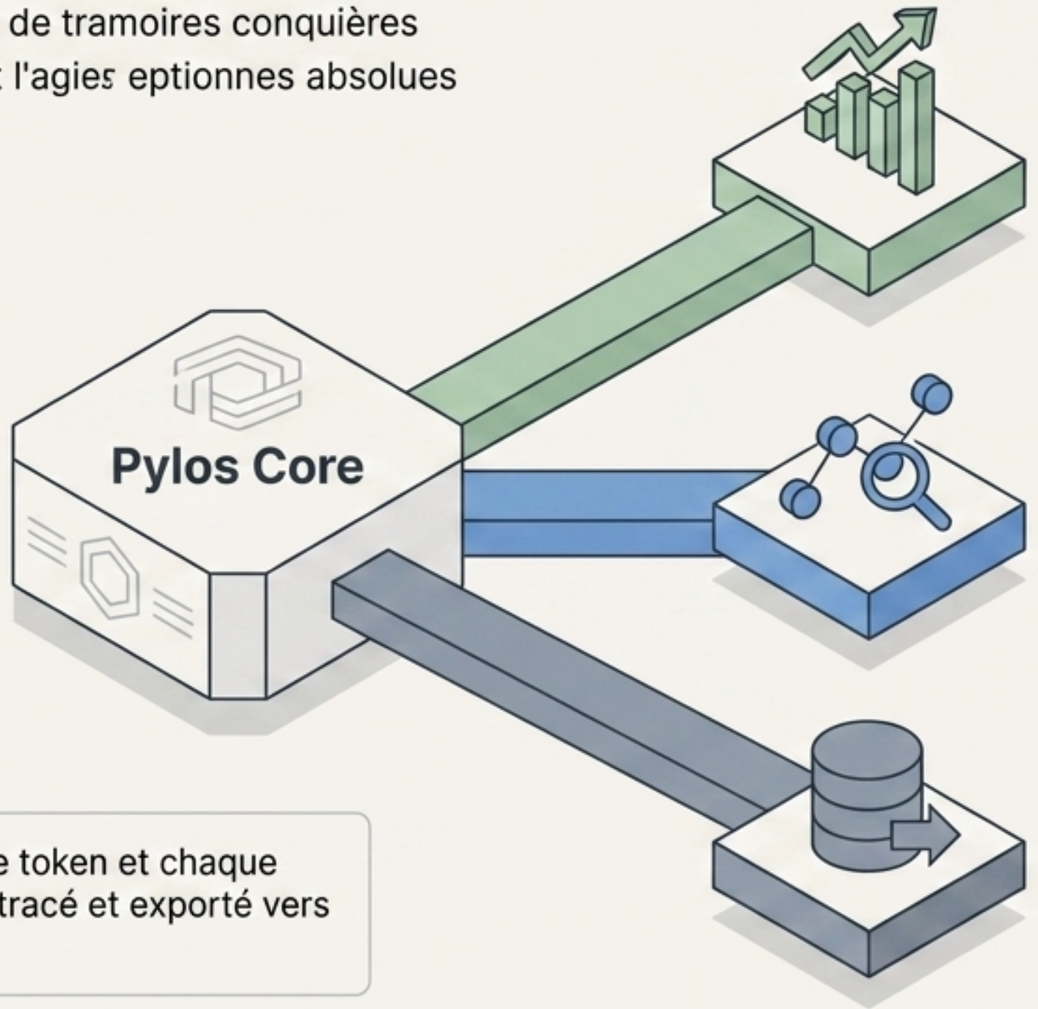
API CRUD de gestion des politiques d'accès. Contrôle précis de qui peut utiliser quel outil.

Intégration native Qdrant pour le RAG et le contexte sémantique étendu.

NotebookLM

Observabilité Absolue : De la Requête au Token

Observabilité absolue : dis posotran la situancie de requêtes au Token. Tor recât de tramoires conquières des data de métrics, logus et l'agies eptionnes absolues au trandrées framne.



Stream 1 : Metrics (Prometheus)

Compteurs requêtes/tokens, Histogrammes latence, TTFT (Time-to-First-Token), Tokens-per-second.

Stream 2 : Tracing (OpenTelemetry)

Export OTLP HTTP, Conventions sémantiques gen_ai.system.

Stream 3 : Logging (SQLite/PostgreSQL)

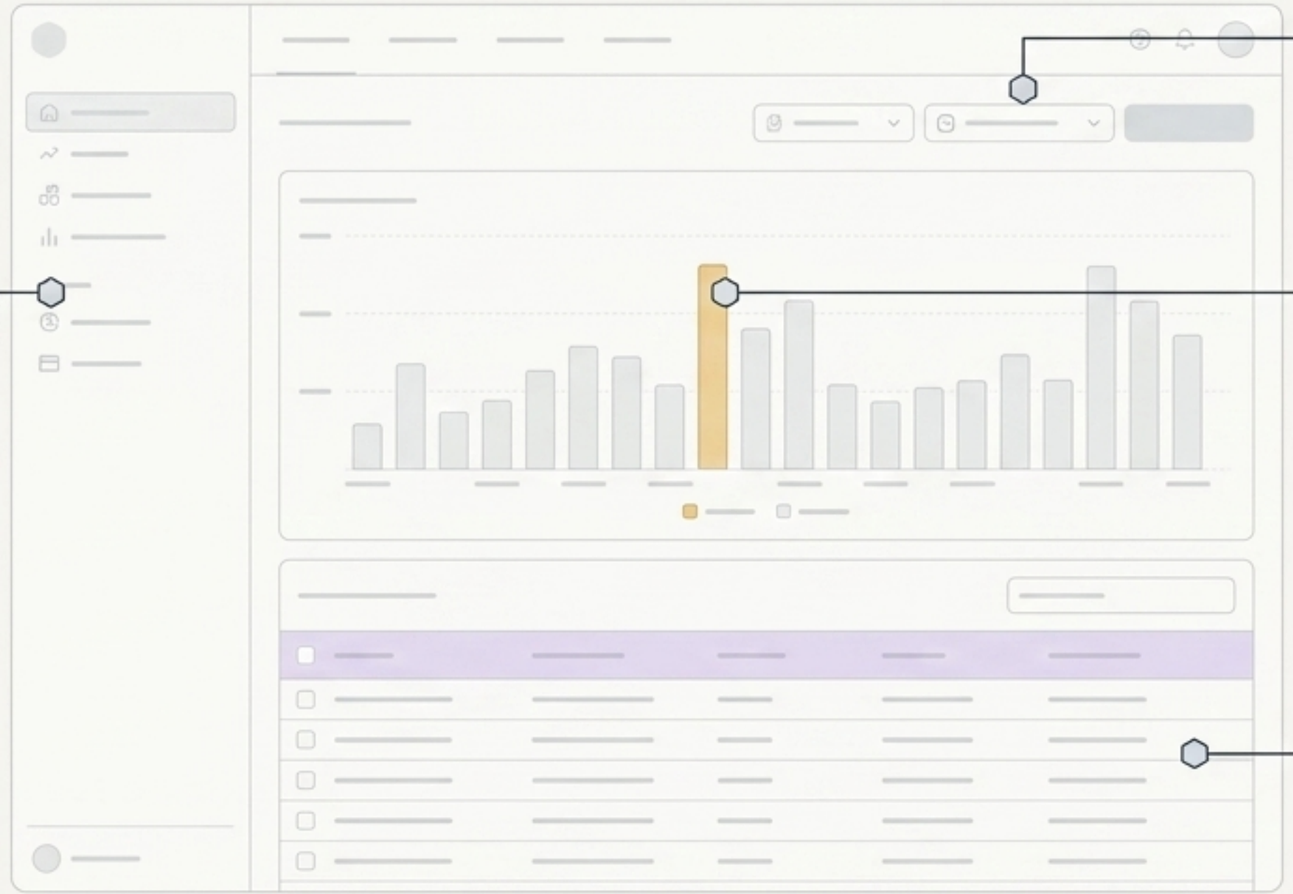
Logs structurés avec requêtes/réponses complètes, coût USD et statut.

Chaque milliseconde, chaque token et chaque centime généré est mesuré, tracé et exporté vers les standards de l'industrie.

NotebookLM

Le Command Center : Administration et Analytique en Temps Réel

Propulsé par React 19, Vite 8, TanStack Query et TailwindCSS



1 Auto-refresh 30s & Filtres temporels (1h à 30 jours)

2 Heatmaps de latence & Analytics de volume / coûts comparés (économies vs GPT-4o)

3 Playground A/B (Comparaison de modèles en temps réel),

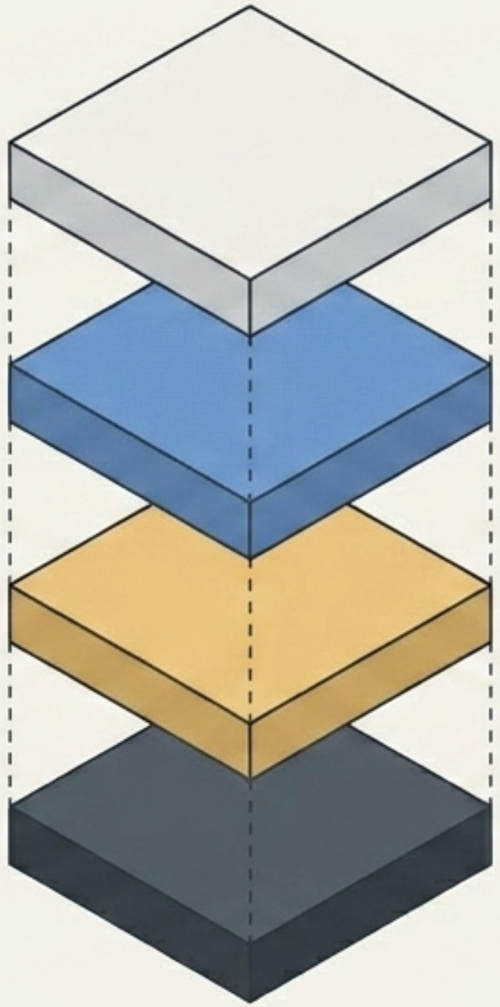
Model Catalog, Budgets & Billing (Seuils Vert/Jaune/Rouge)

4 Logs d'investigation avec modal détaillé par requête

NotebookLM

Architecture Hexagonale : La Puissance de Rust

Réécrit entièrement en Rust pour garantir la sécurité mémoire, maximiser la performance concurrentielle et offrir une latence minimale indispensable pour le streaming LLM.



pylos-server

Axum 0.7 HTTP server, routes, middleware, Tokio

pylos-application

Use cases, orchestration, stores, plugins

pylos-infrastructure

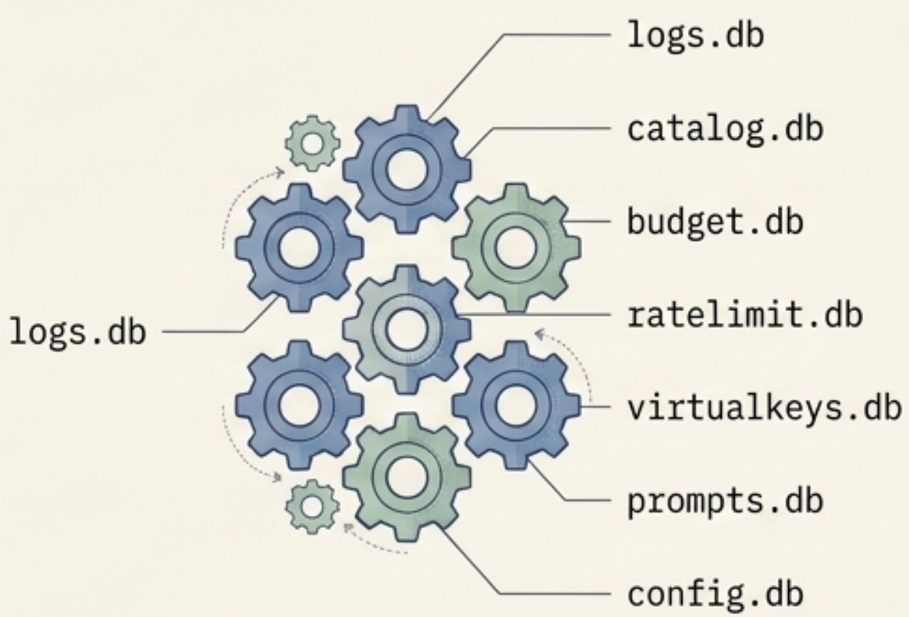
Provider adapters, AWS/Azure SDKs, observability exports

pylos-core

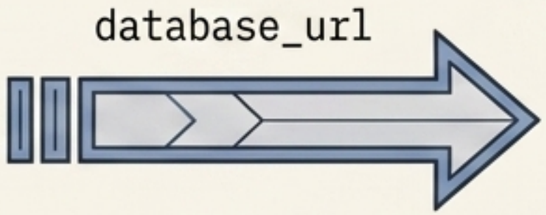
Domain entities, traits, configuration types

NotebookLM

Matrice de Persistance : De l'Edge à l'Enterprise



Mode SQLite
(Zero Setup, WAL mode)





Consolidation PostgreSQL

Persistance d'entreprise unifiée pour un déploiement à grande échelle.

Configuration centralisée (`pylos.json`) avec Hot-Reload instantané via l'UI ou l'API (`POST /config/reload`), protégée par hashing SHA-256.

NotebookLM

Déploiement Cloud-Native et CI/CD



Images multi-arch (amd64/arm64)

Générées via GitHub Actions (Lint, Test, Build, Push GHCR).

Stack Complète via docker-compose up

Inclut Pylos, UI, Prometheus, Grafana et Qdrant en une commande.

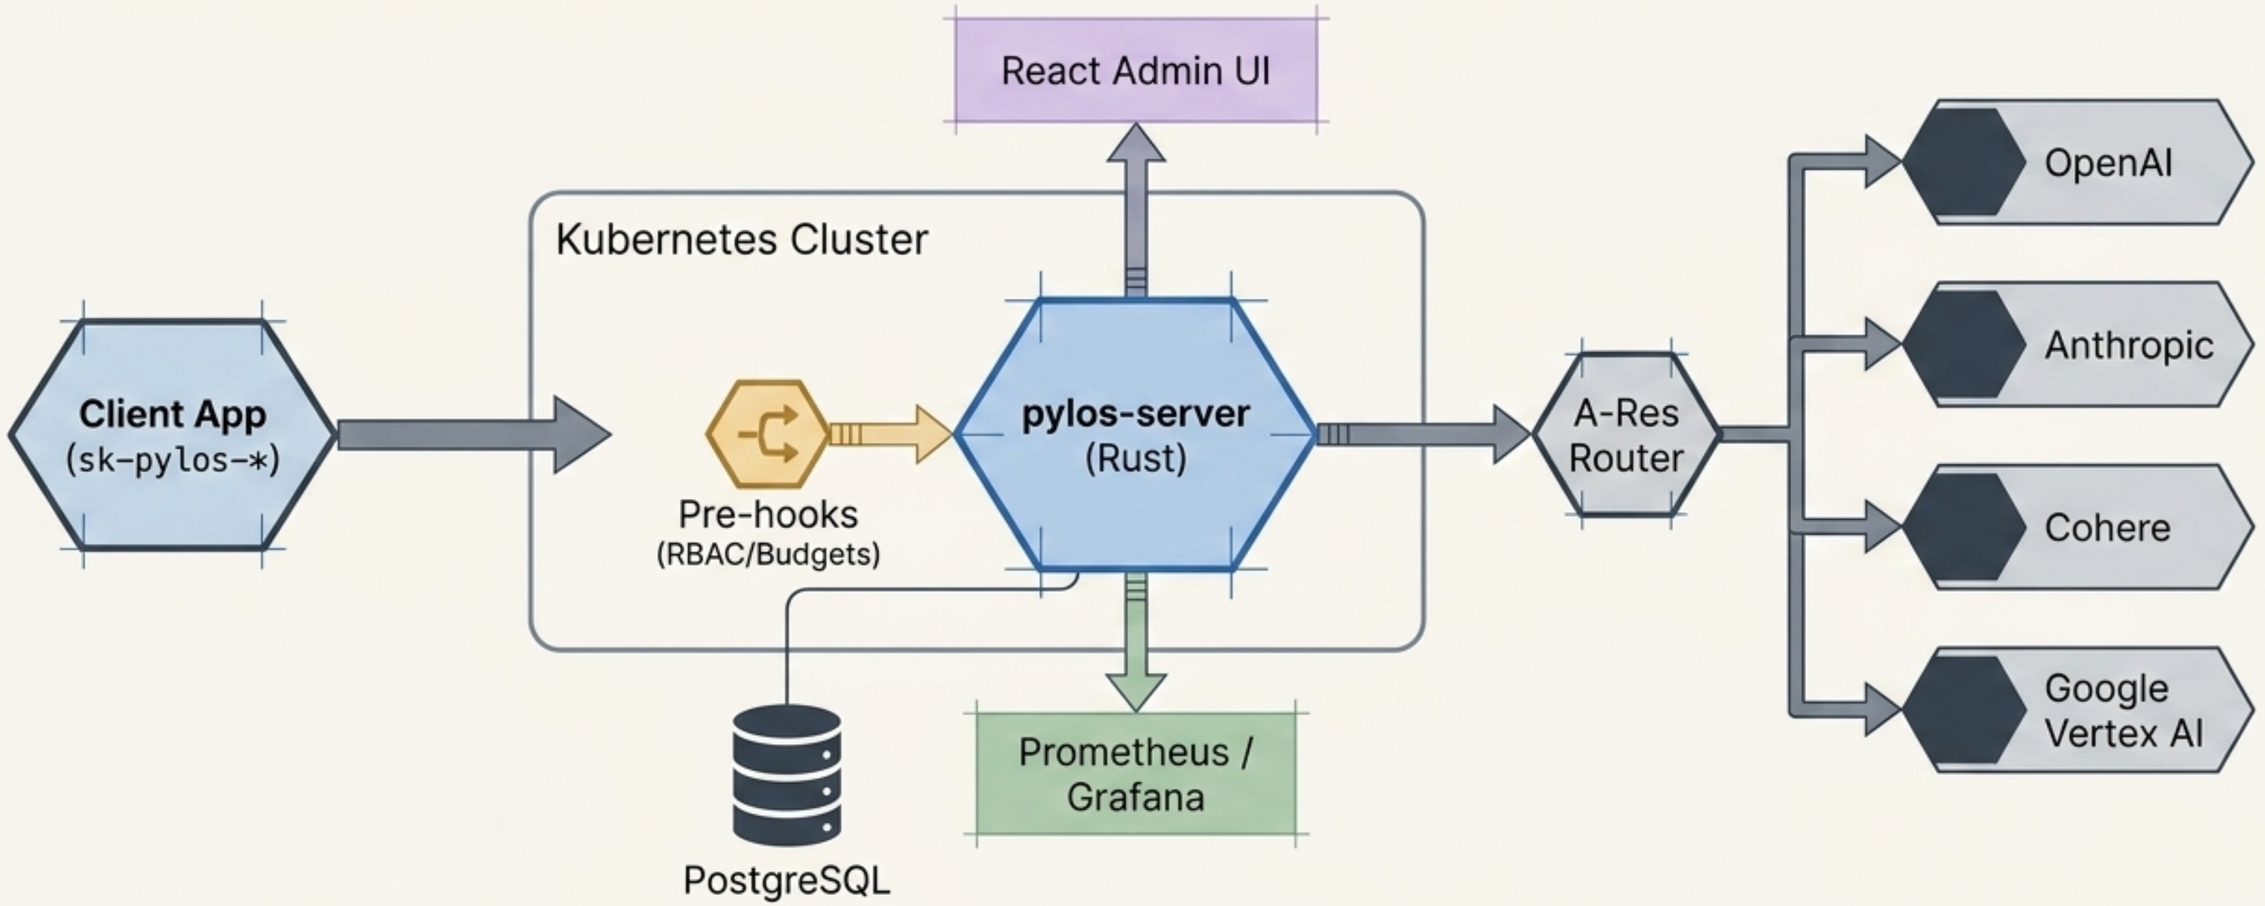
Déploiement Kubernetes

Via Helm Chart dédié, compatible GitOps et ArgoCD.

Conçu pour être opérationnel en quelques minutes sur le poste d'un développeur, et **parfaitement scalable** sur un cluster Kubernetes en production.

NotebookLM

La Synthèse Architecturale : Le Moteur Pylos



Une fondation technique irréprochable qui transforme la complexité et les coûts incontrôlés des LLMs en un utilitaire réseau prévisible, sécurisé et hautement performant.

NotebookLM