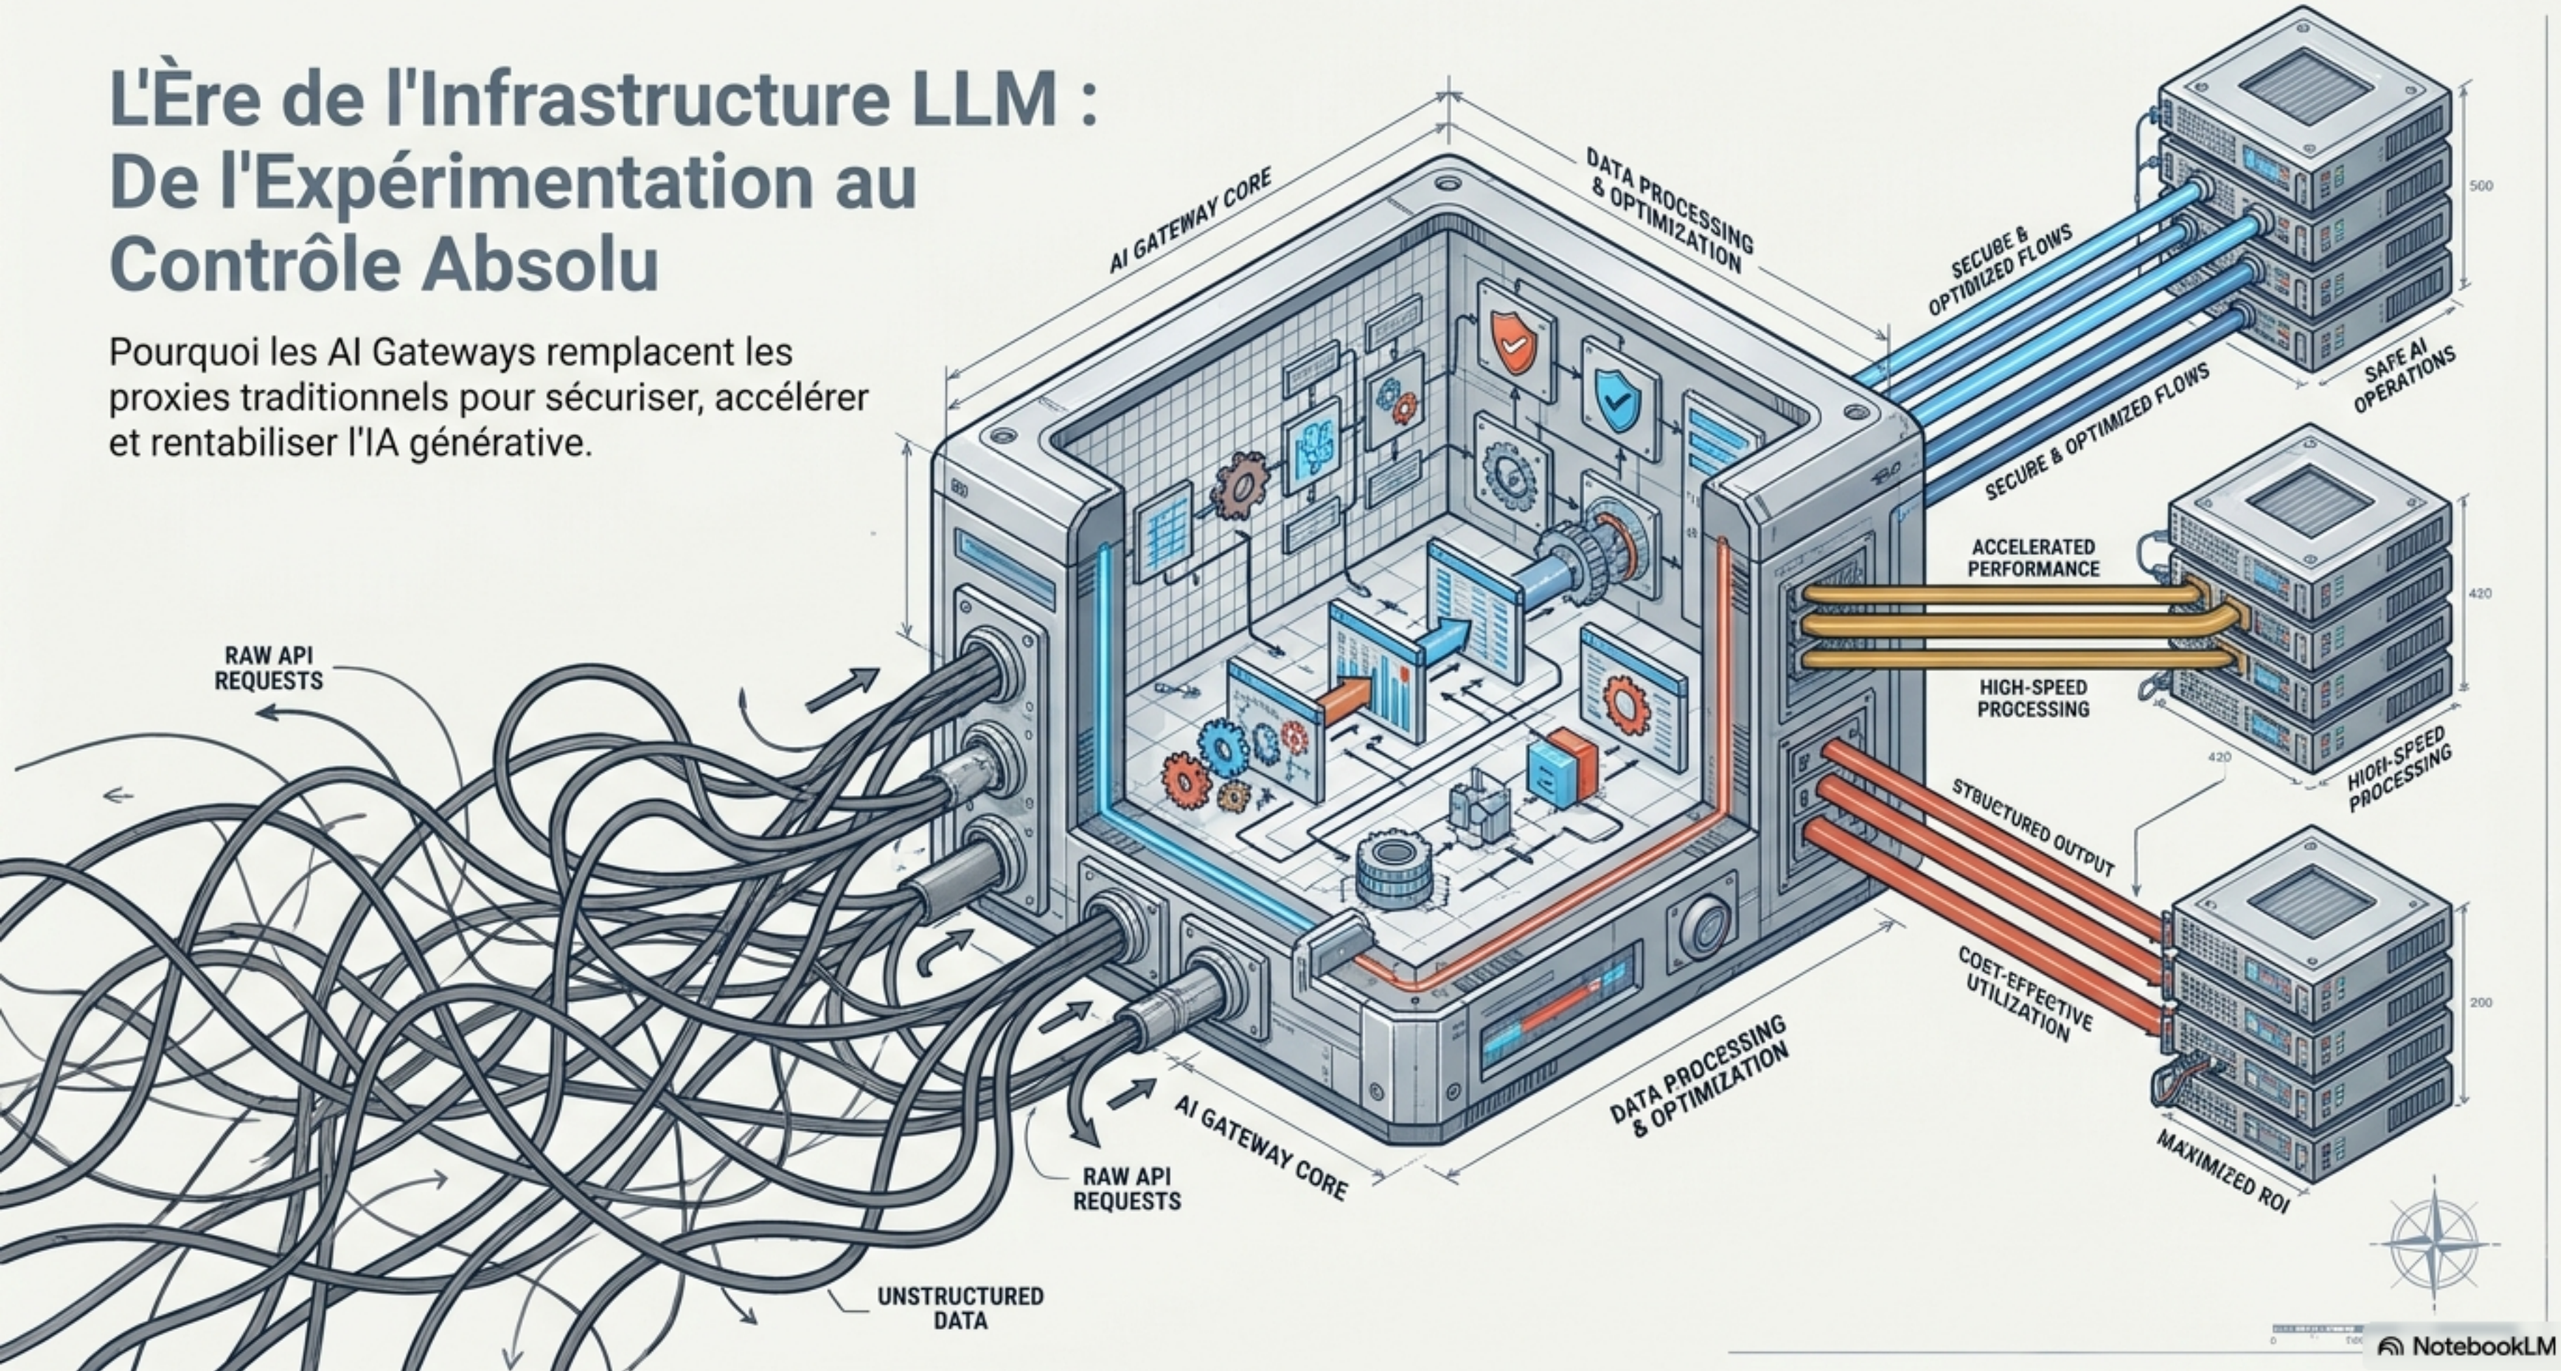
# L'Ère de l'Infrastructure LLM : De l'Expérimentation au Contrôle Absolu

Pourquoi les AI Gateways remplacent les proxies traditionnels pour sécuriser, accélérer et rentabiliser l'IA générative.




NotebookLM

# Le Mur de l'Industrialisation LLM



## Coûts & Quotas

Les limites ne sont plus en requêtes par seconde (RPS) mais en TPM (Tokens Par Minute). Une simple erreur de boucle peut ruiner un budget.

## Latence & Résilience

Pannes de foumisseurs (429) et temps de réponse TTFT variables exigent un routage dynamique impossible pour un proxy passif.

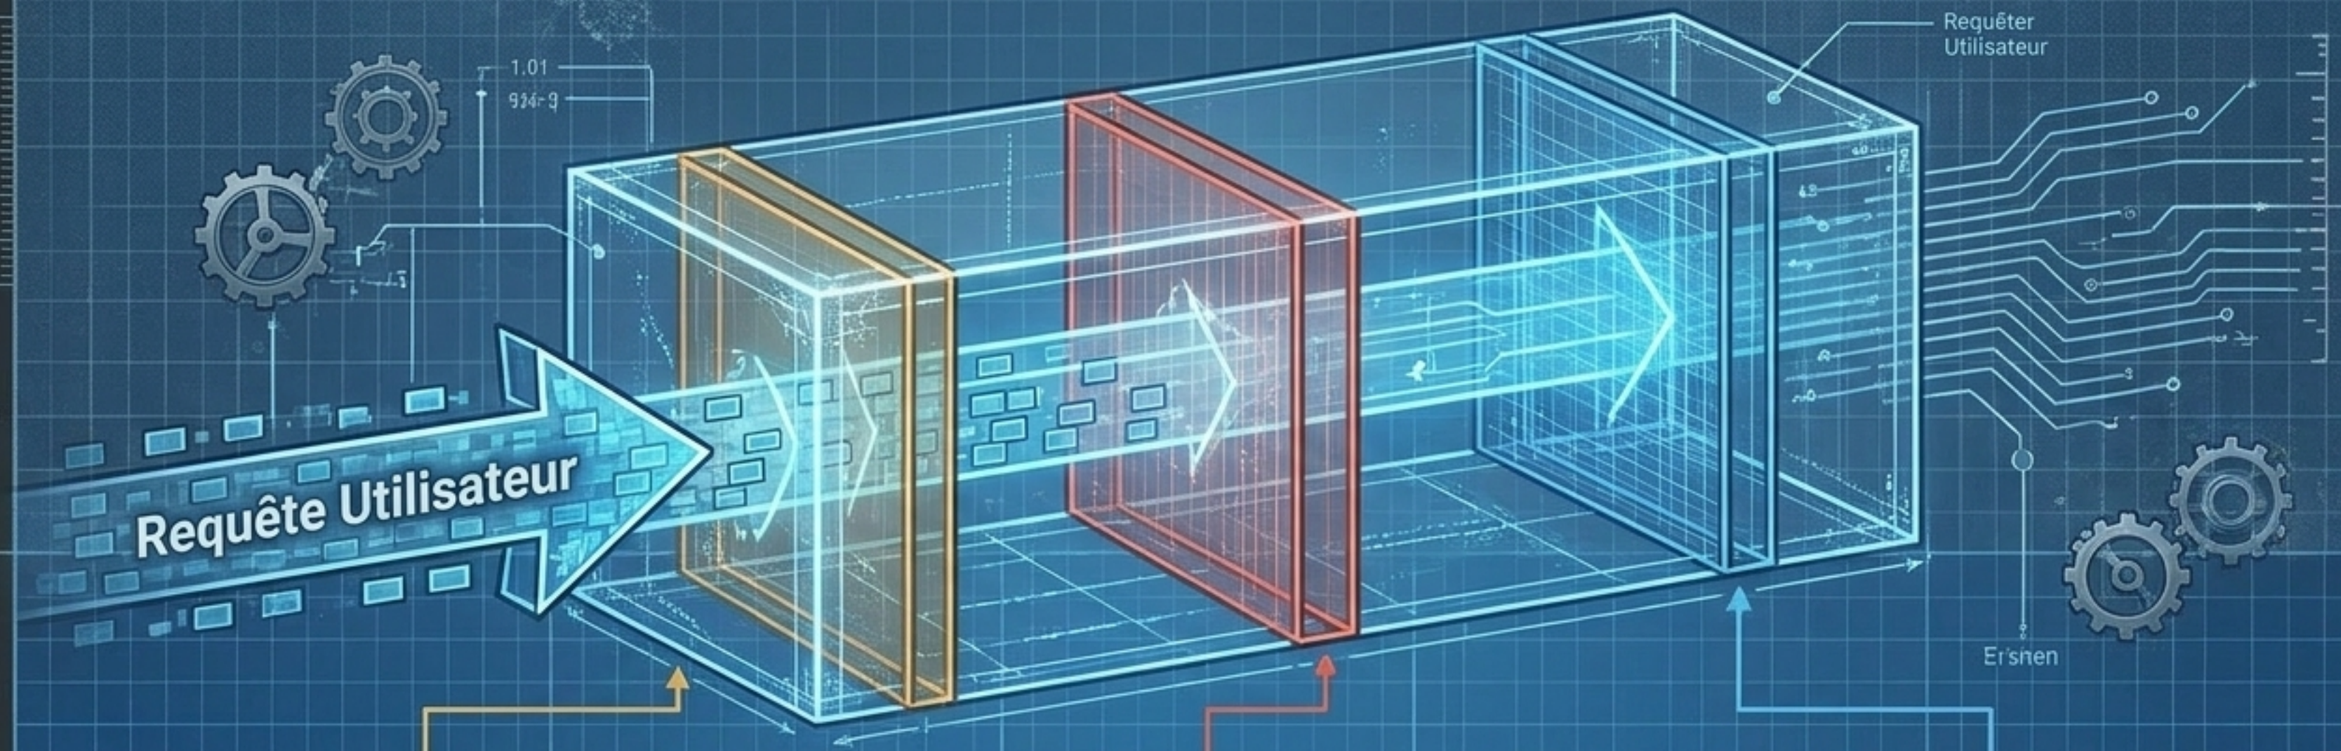
## Gouvernance & Sécurité

Les prompts contiennent des données sensibles (PII). La passerelle doit comprendre la sémantique, pas juste le protocole HTTP.




NotebookLM

# Anatomie d'une AI Gateway




## Maîtrise Financière

**Semantic Caching** : 0 token consommé sur les réponses connues.

**Token-aware Rate Limiting** : Blocage basé sur les budgets réels.

## Haute Performance

**Smart Fallbacks** : Bascule transparente entre fournisseurs.

**Load Balancing** : Répartition multi-clés en Round-Robin.

## Sécurité & Observabilité

**PII Data Redaction** : Anonymisation locale à la volée.

**Prompt Guardrails** : Blocage des injections sémantiques.

NotebookLM

# Le Paysage des Solutions du Marché

Performance & Débit

Complexité & Fonctionnalités

## Q1

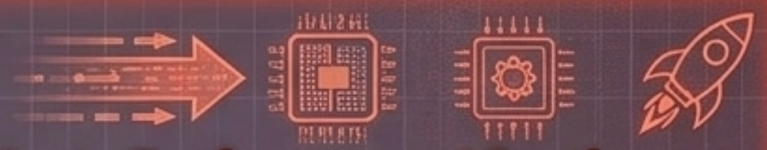


### Open Source & Lightweight

Ex: LiteLLM

Standardisation au format OpenAI.
Idéal pour le prototypage rapide.
Limité par le plafond de débit lié au GIL Python.

## Q4



### Haute Performance / Système

Ex: Pylos (Rust/Go)

La nouvelle frontière. Gestion de milliers de requêtes par seconde avec latence ajoutée quasi nulle (< 2ms). Contrôle total.

## Q2



### API Management Traditionnel

Ex: Kong AI, APIM Cloud

Extensions de solutions Enterprise.
Forte intégration cloud/on-premise existante, mais souvent lourdes à déployer.

## Q3



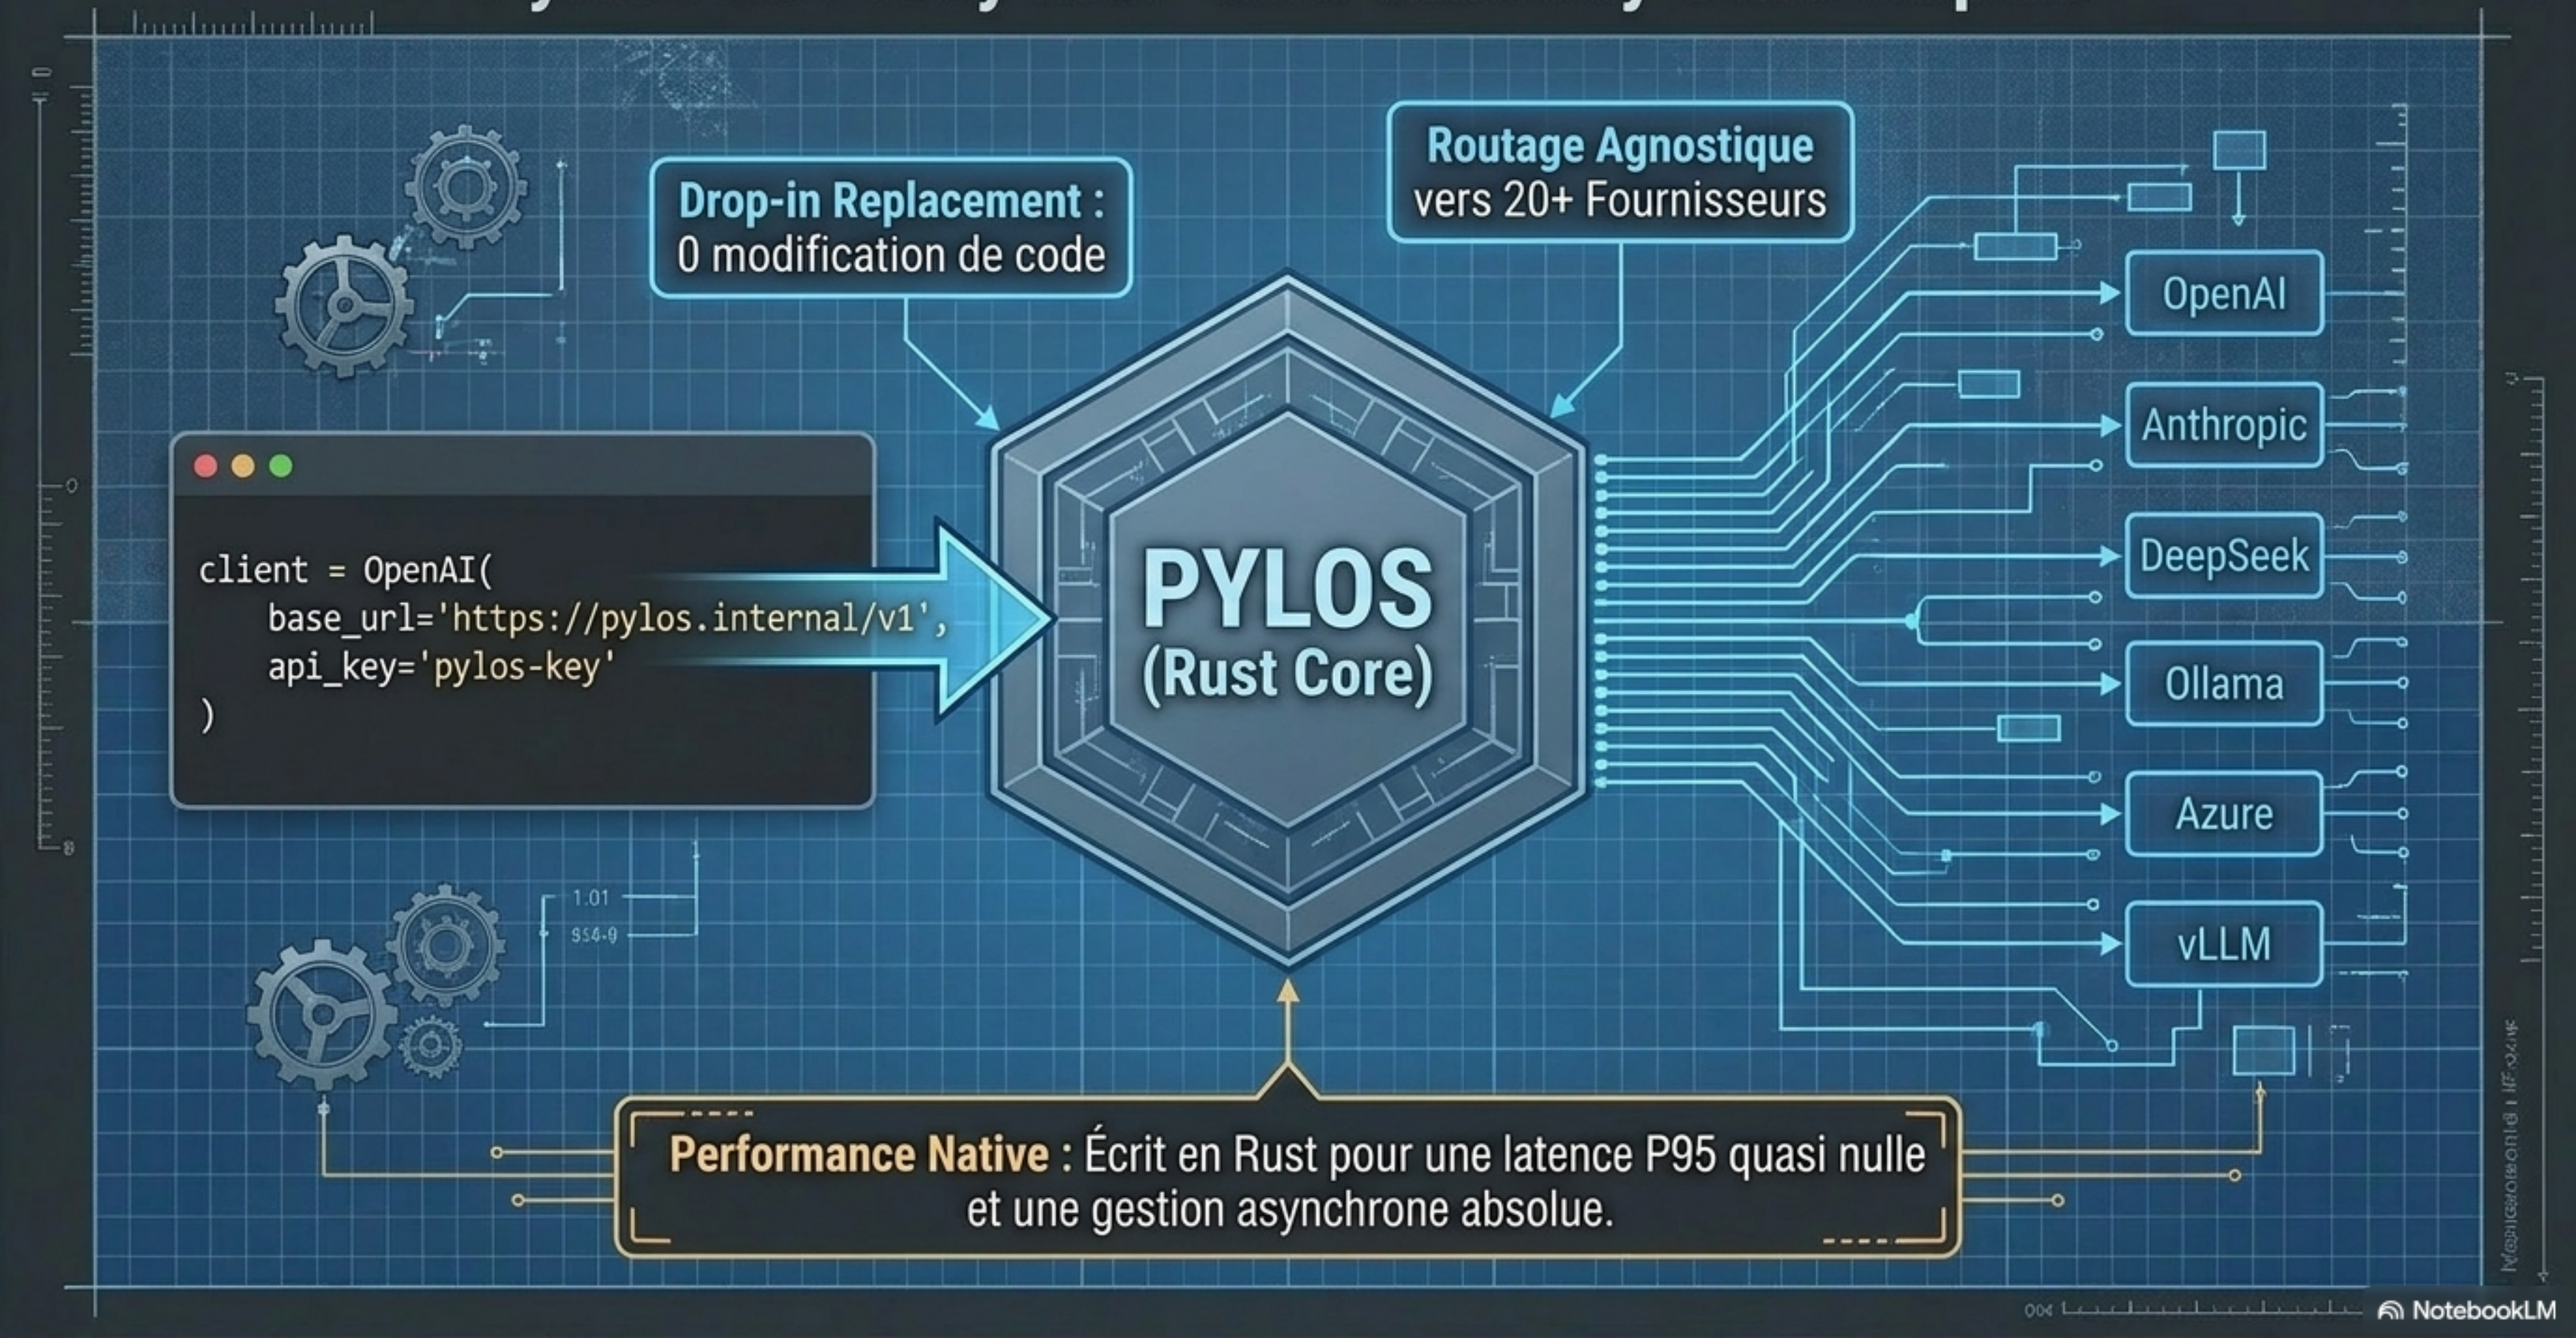
### LLMOps & Observabilité

Ex: Portkey, Langfuse

Proxies orientés analytique. Excellents pour le débogage de chaînes complexes et le calcul précis des coûts d'agents.

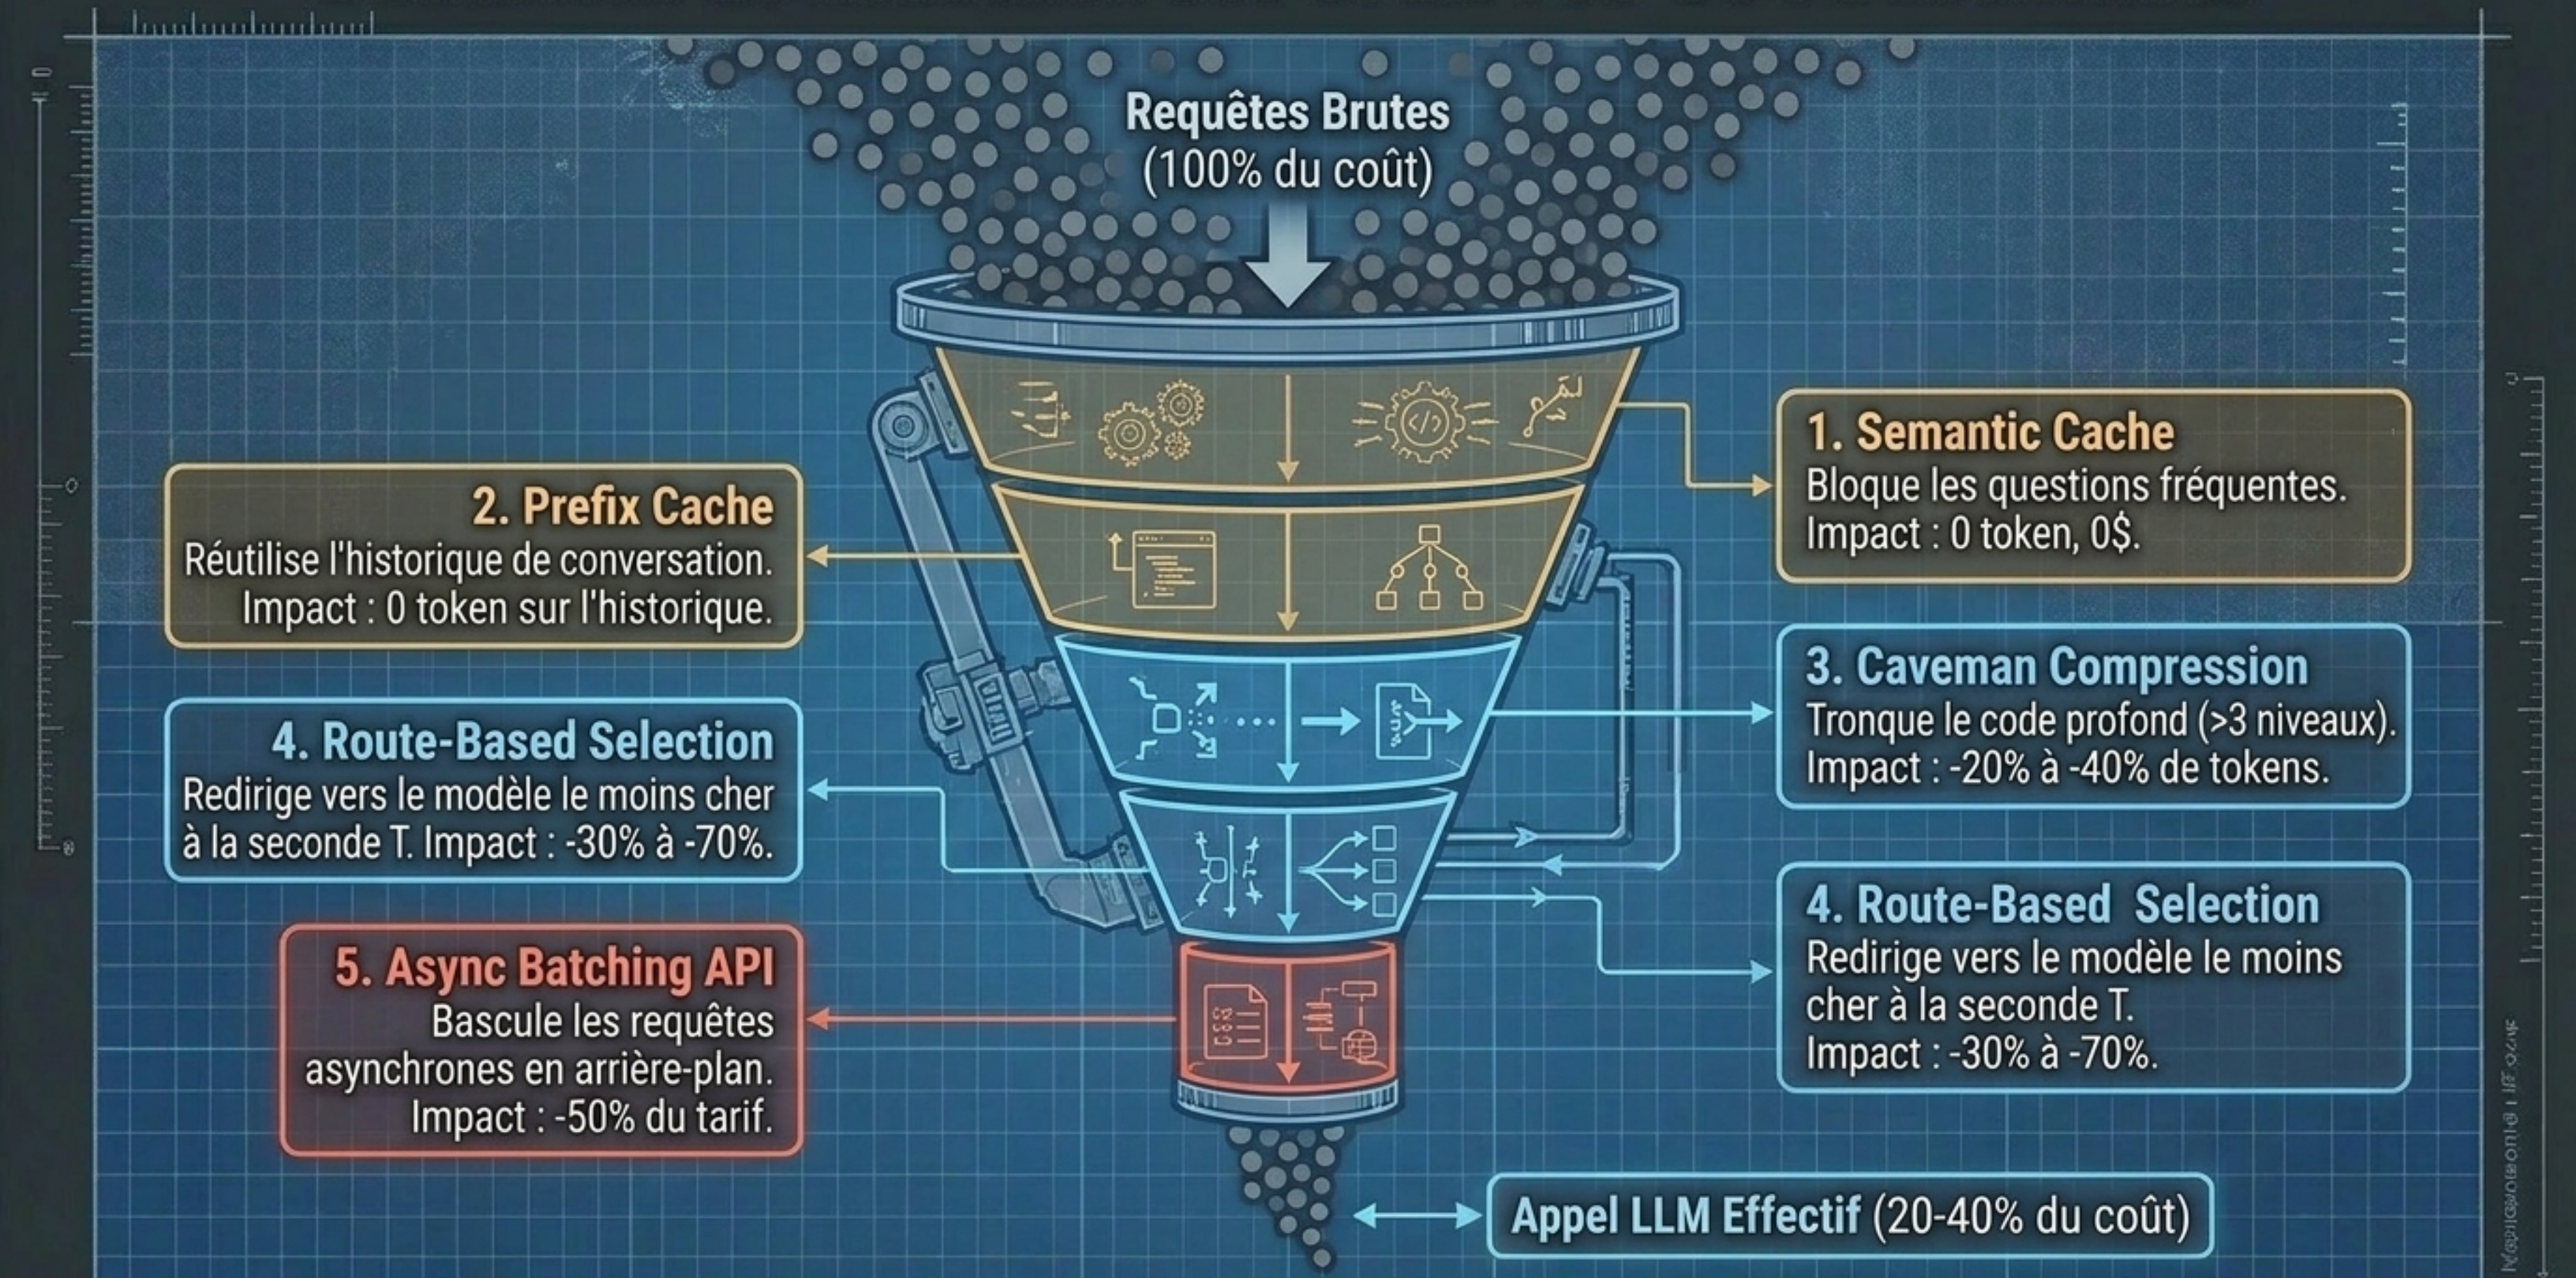
NotebookLM

# Pylos : Le Proxy MCP & AI Gateway Ultra-Rapide




NotebookLM

# L'Entonnoir de Réduction des Coûts : 60-80% d'Économies




NotebookLM

# Les 3 Niveaux de Cache : Au-delà de l'Exactitude



## SemanticCachePlugin

Le Filtre Conceptuel

**Mécanisme**

Base vectorielle (Qdrant) + similarité Cosine (Seuil 0.90).

**Bénéfice**

0 requête LLM pour des reformulations de questions (Support client, FAQ).



## PrefixCachePlugin

La Mémoire de Conversation

**Mécanisme**

Cache en mémoire vive (Moka) sur les préfixes de messages 1..N.

**Bénéfice**

Réduit le temps de traitement initial (TTFT) de 40-60% grâce au KV Cache des fournisseurs.



## CacheAlignerPlugin

Le Stabilisateur de Contexte

**Mécanisme**

Nettoyage sémantique du contenu volatil avant envoi.

**Bénéfice**

Normalise les métadonnées pour éviter les 'Cache Miss' massifs et inutiles.

NotebookLM

# L'Alignement de Cache en Action

## AVANT

```
{
  'system': 'Tu es un assistant.',
  'user_id': '550e8400-e29b-41d4-a716',
  'date': '2023-10-24T12:00:00Z',
  'query': 'Synthétise ce rapport.'
}
```

CACHE MISS



Pre-hook
Aligner

## APRÈS

```
{
  'system': 'Tu es un assistant.',
  'user_id': '{UUID}',
  'date': '{DATE}',
  'query': 'Synthétise ce rapport.'
}
```

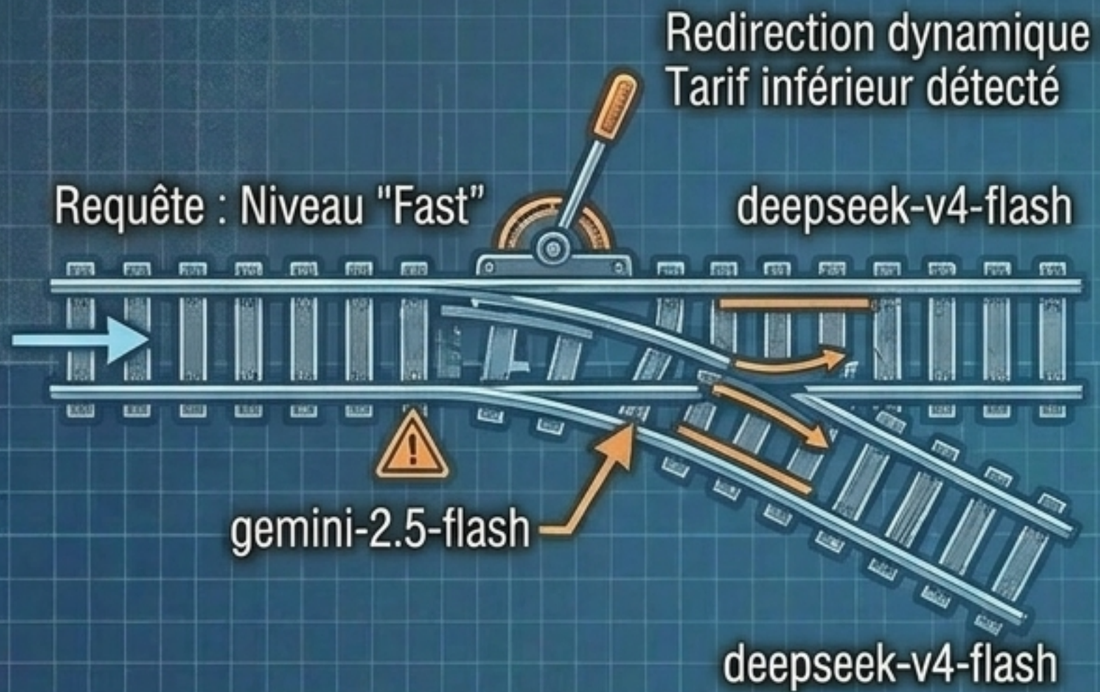
KV CACHE HIT

Les UUIDs et horodatages détruisent le cache des fournisseurs (DeepSeek, Anthropic, OpenAI).
En masquant ces éléments volatils, le System Prompt reste en cache,
réduisant le temps de prétraitement de 30-50%.

NotebookLM

# Routage Adaptatif & Batching Intelligent

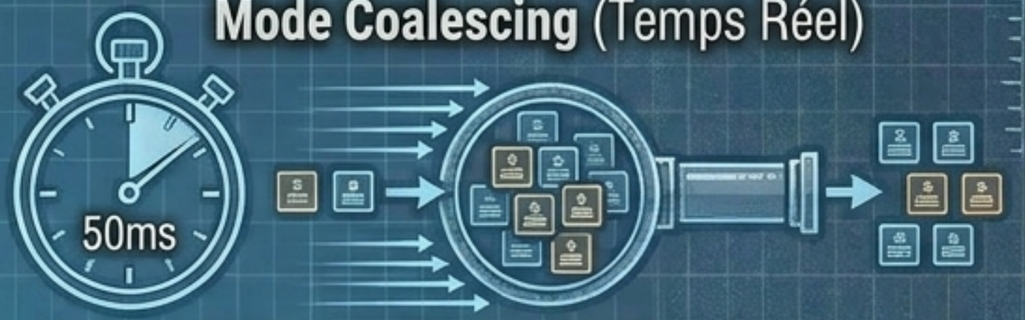
## Routage par Opportunité




Maintien strict de la qualité.
Un modèle 'Pro' bascule vers un 'Pro',
un modèle 'Fast' vers un 'Fast'.

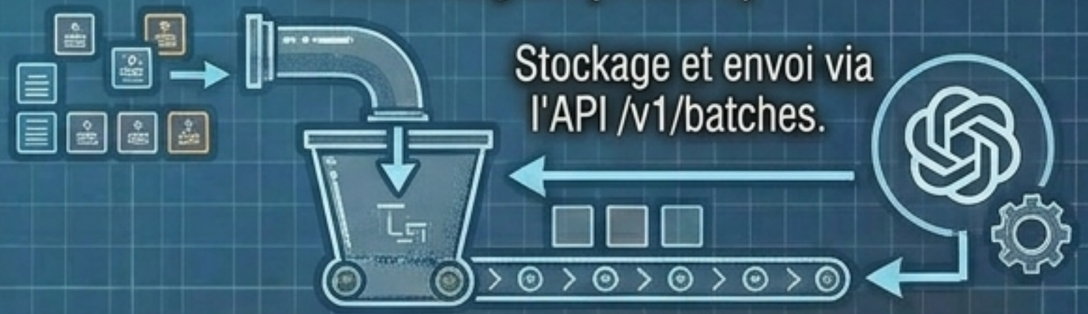
## Les Modes de Batching

### Mode Coalescing (Temps Réel)




Accumulation sur 50ms puis libération groupée
pour optimiser la couche de transport.

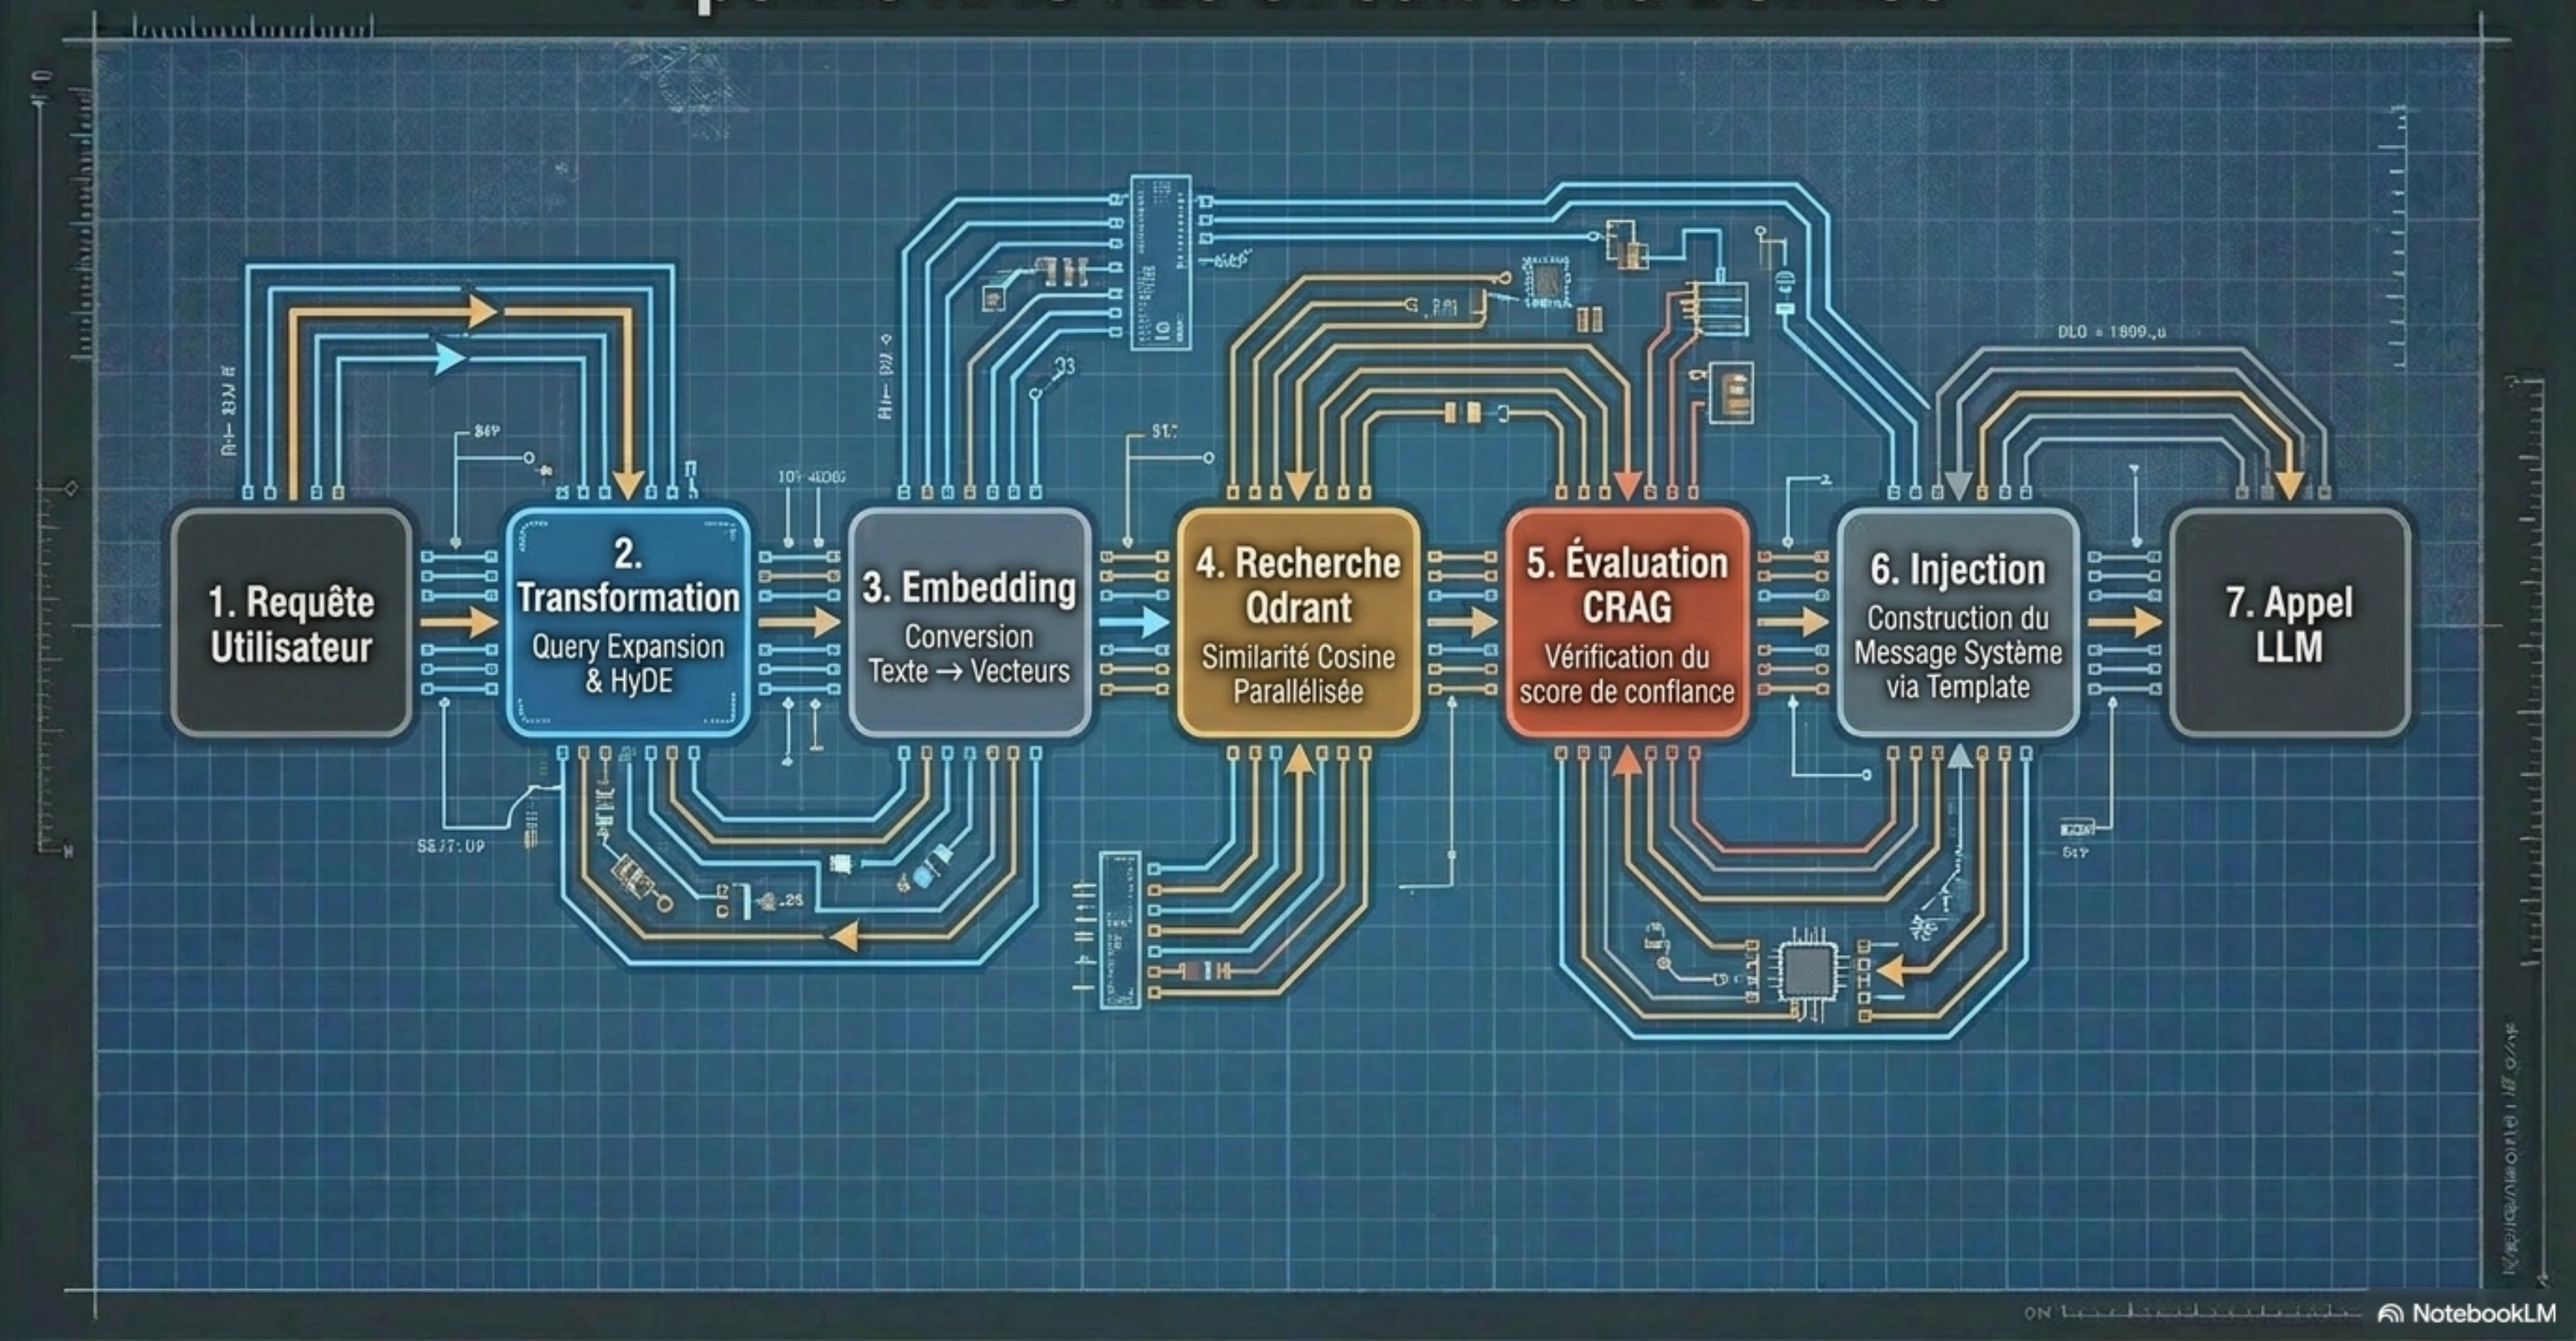
### Mode Async (Différé)




Stockage et envoi via l'API /v1/batches.
Récupération par polling. Réduction du coût de 50%.

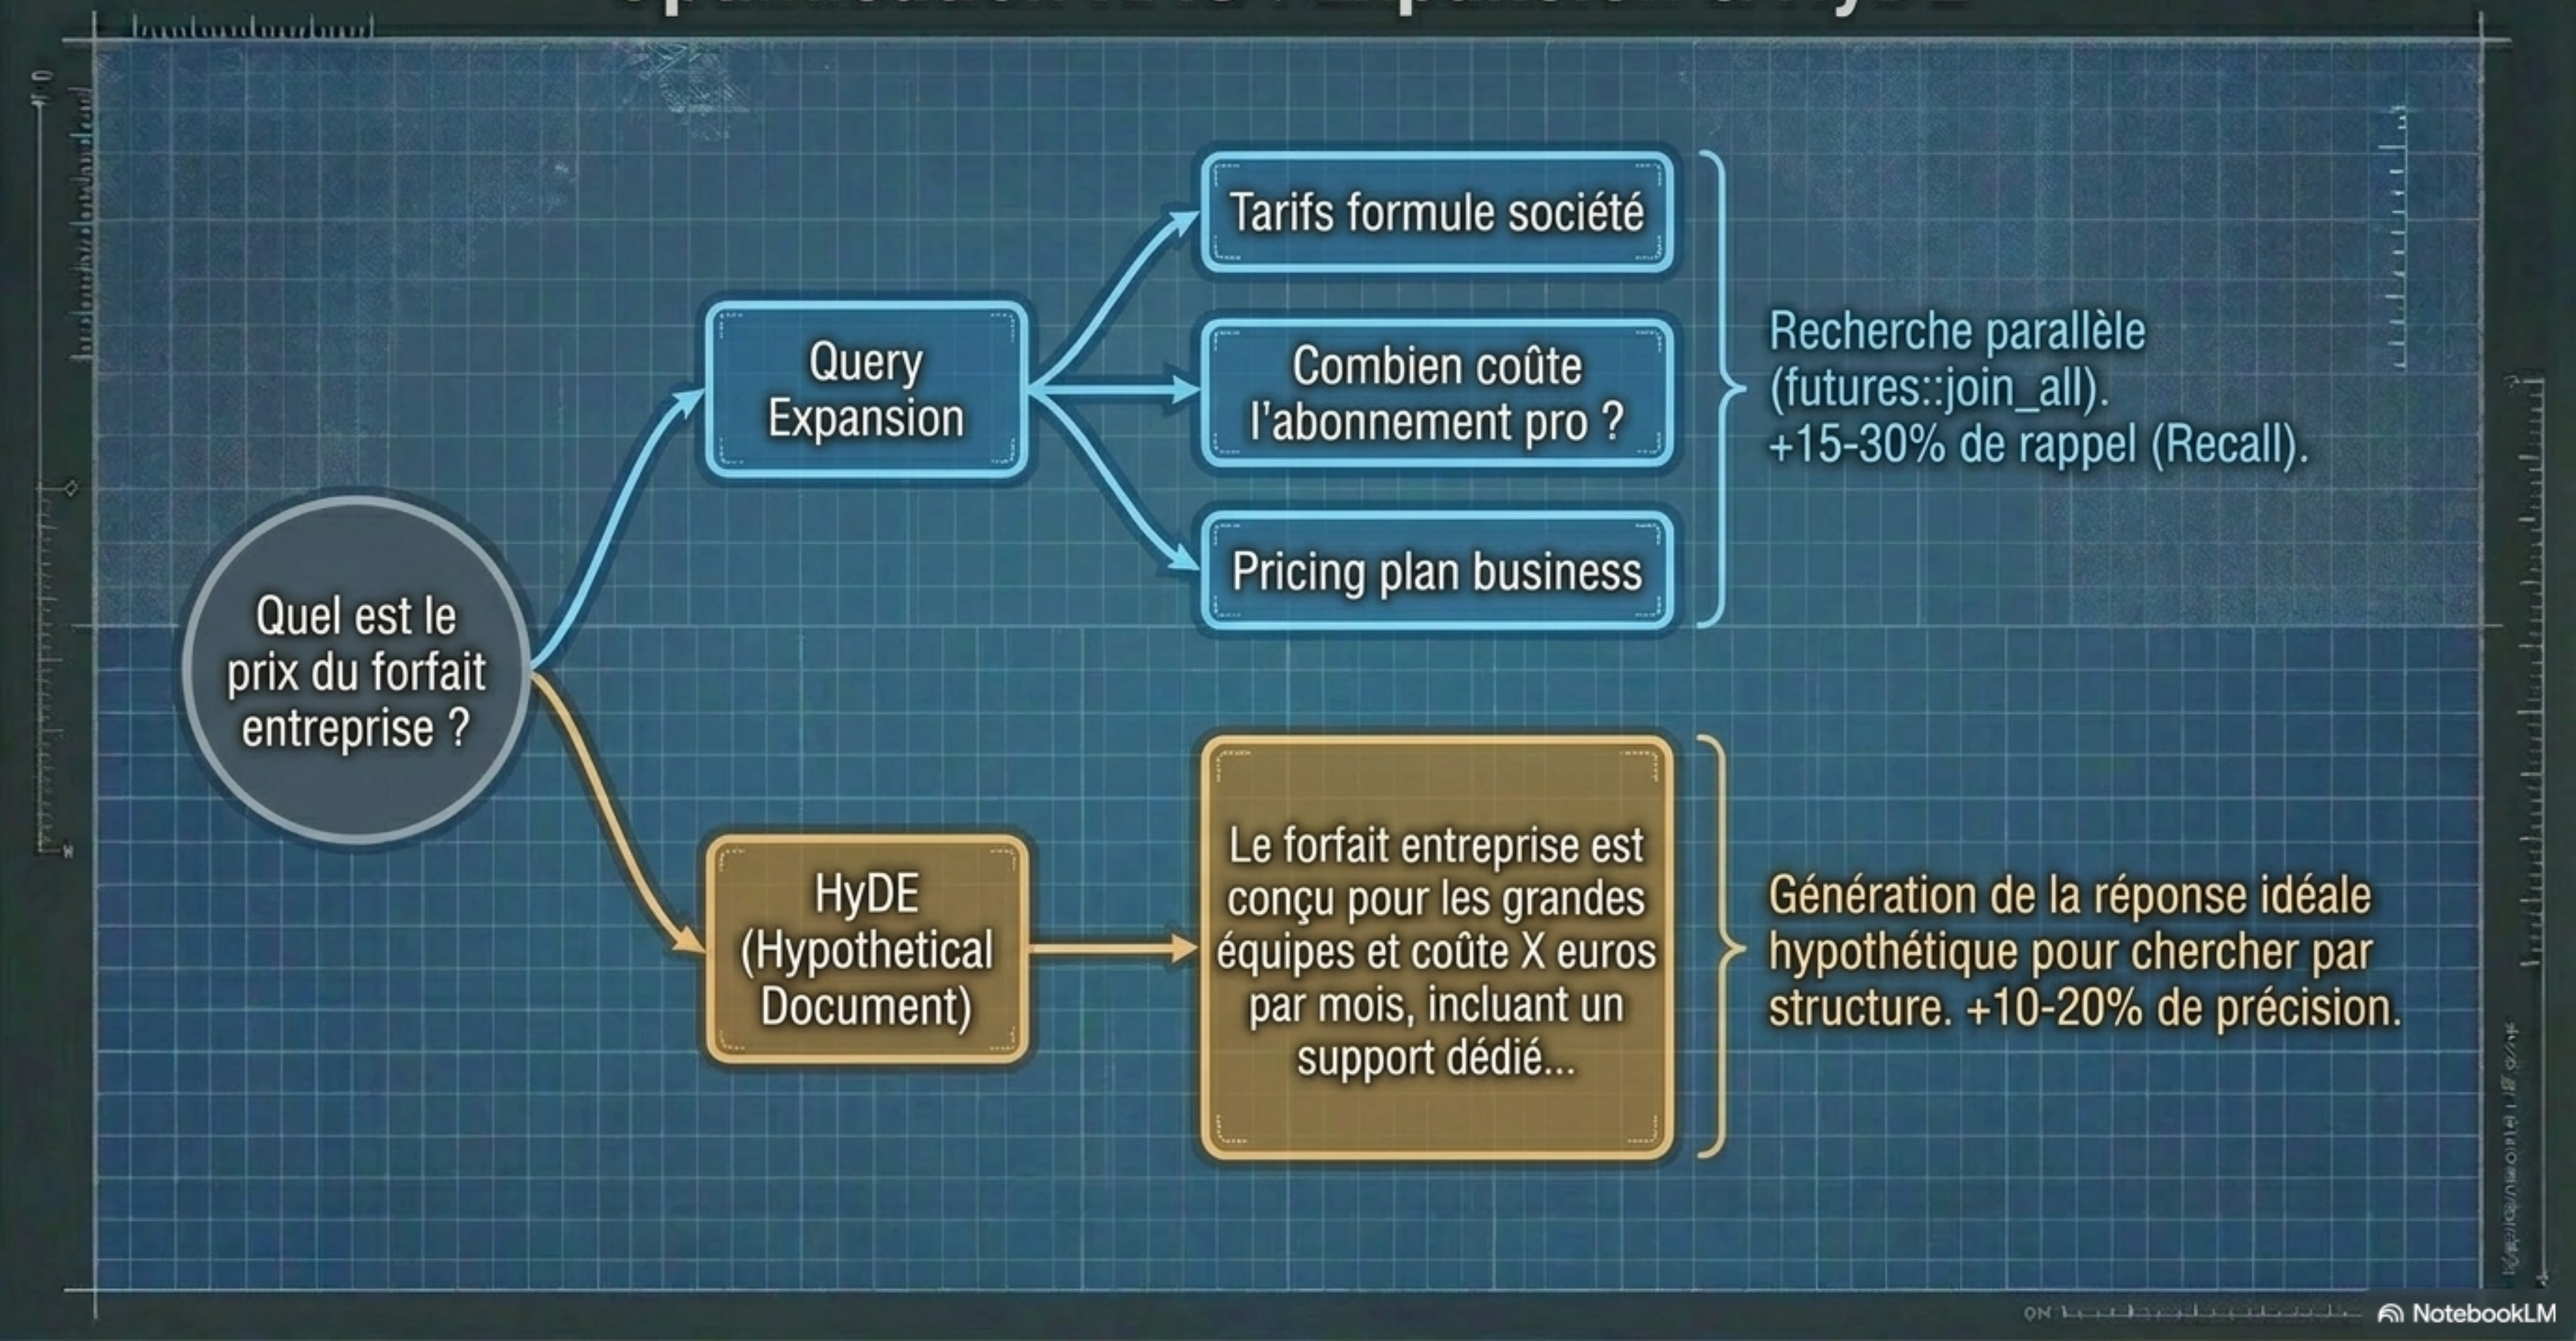
NotebookLM

# Pipeline RAG : Le Circuit de la Donnée




NotebookLM

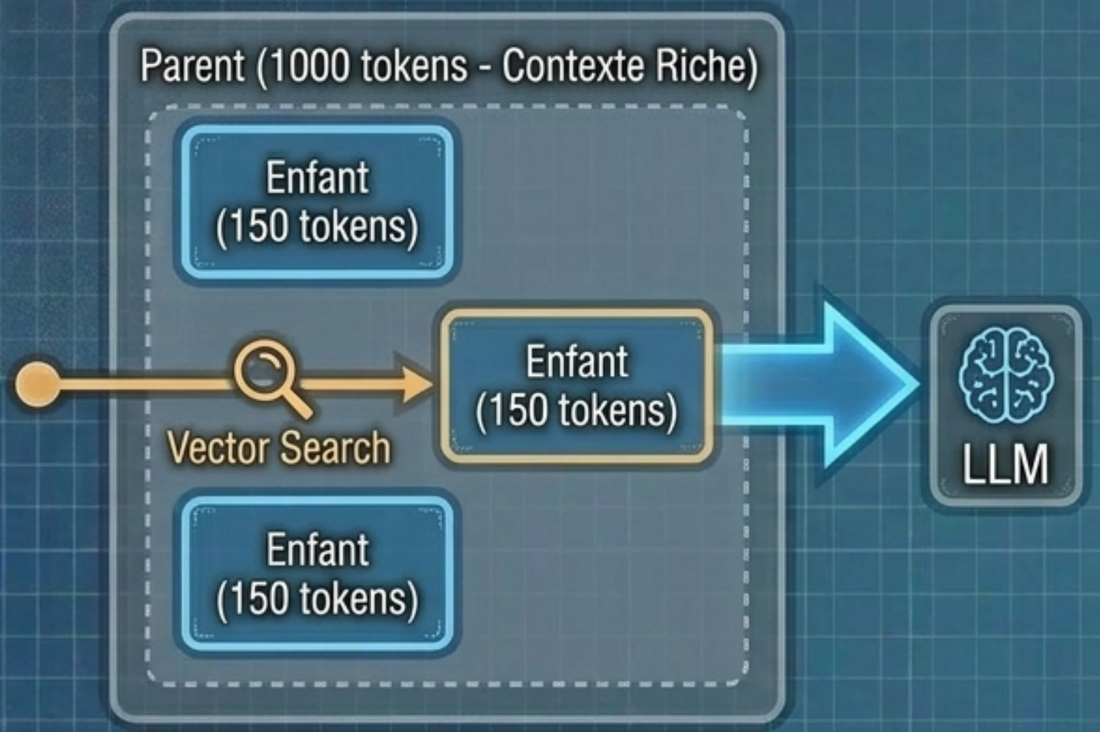
# Optimisation RAG : Expansion & HyDE




NotebookLM

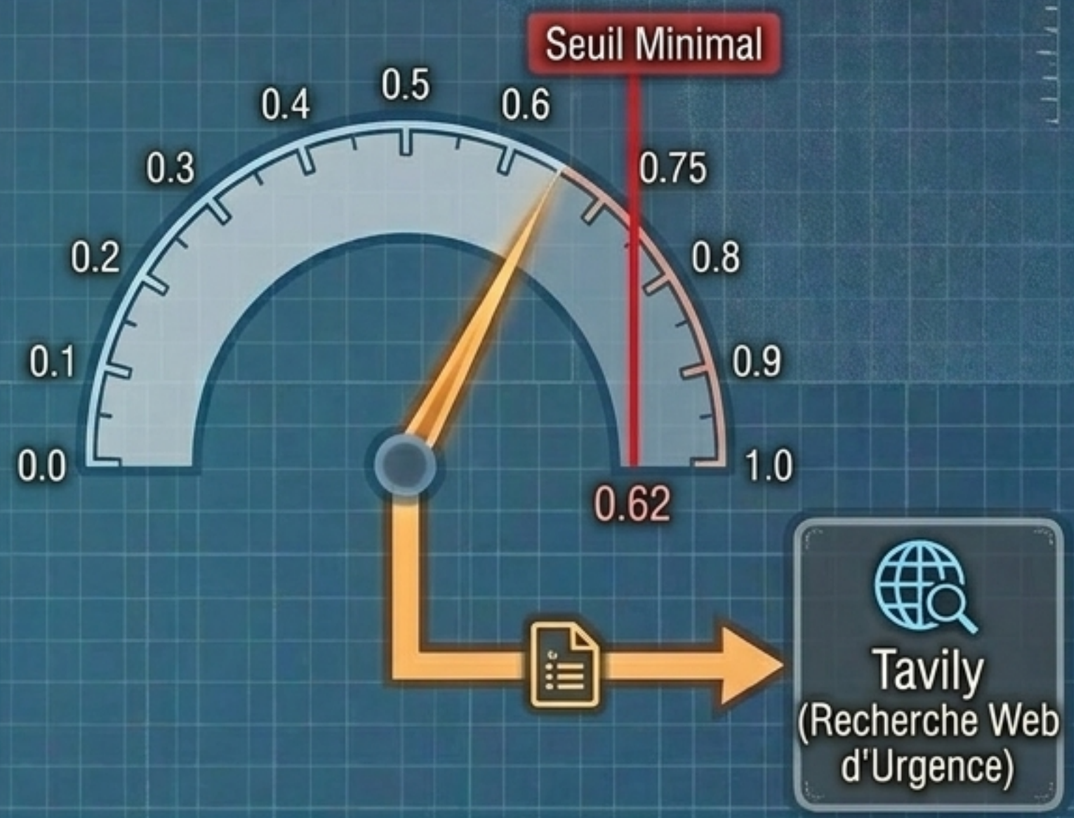
# Éviter l'Hallucination : Précision & Correction

## Parent-Child Chunking




La recherche vise l'extrait précis, mais le LLM reçoit le document entier pour comprendre le contexte.

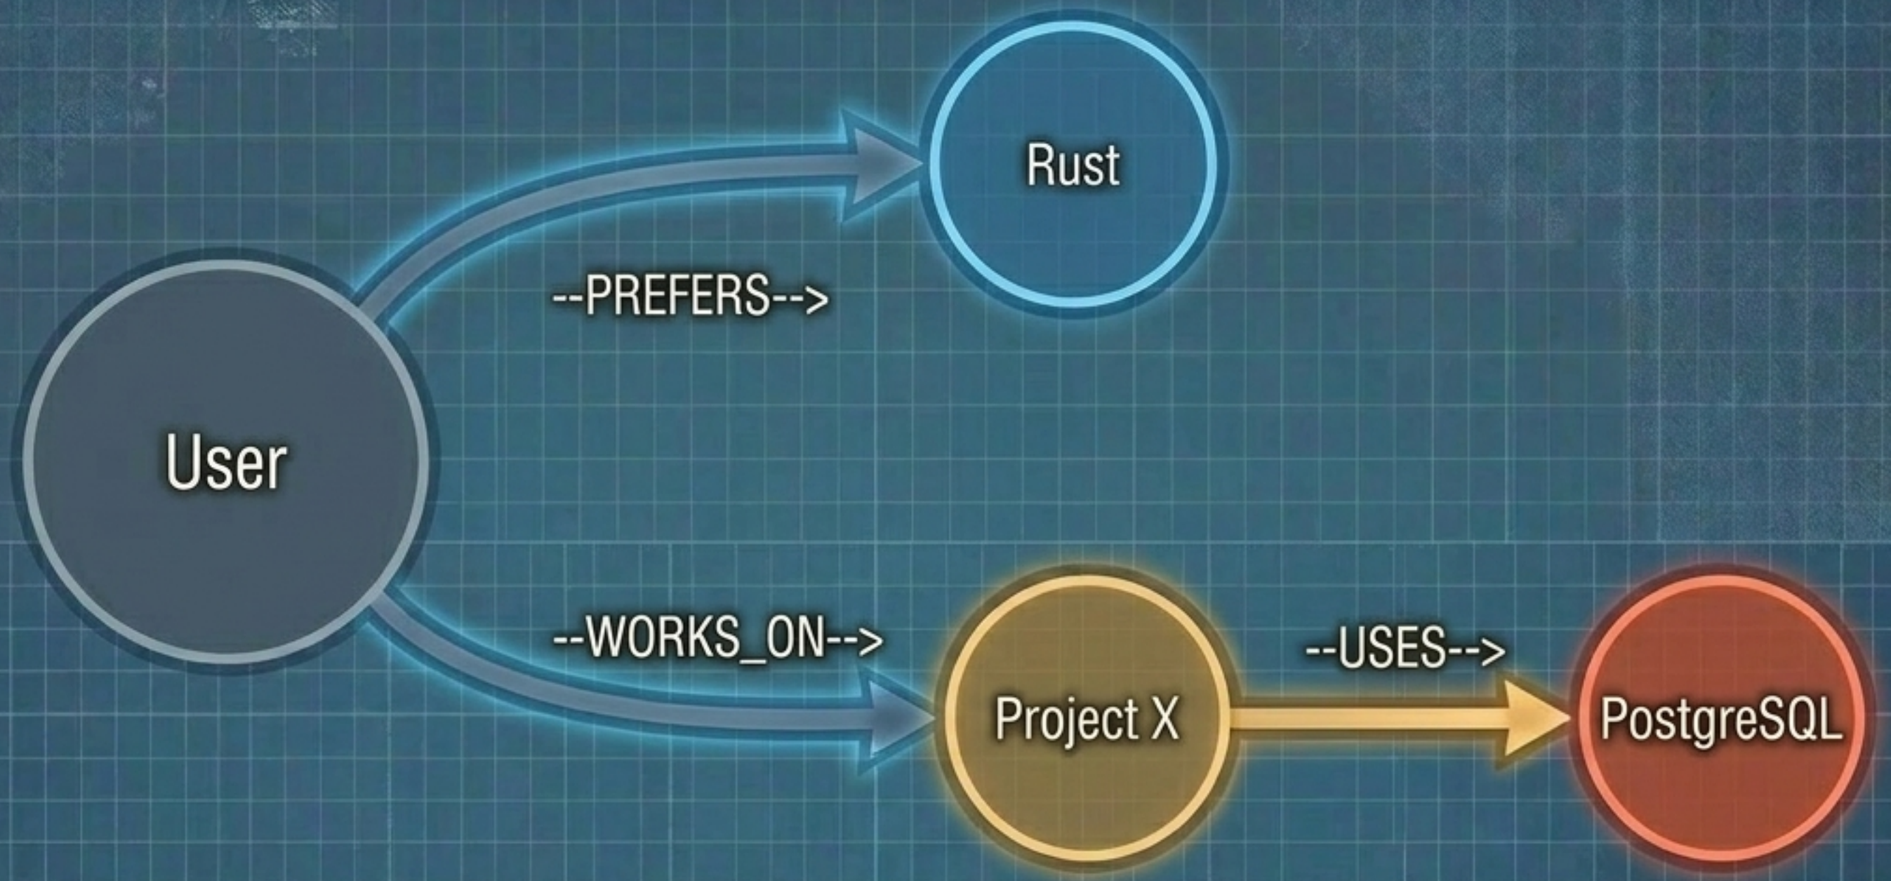
## CRAG (Corrective RAG)




Si la confiance de la base vectorielle est faible, le flux est redirigé vers le web en temps réel.

NotebookLM

# La Mémoire Cross-Agent

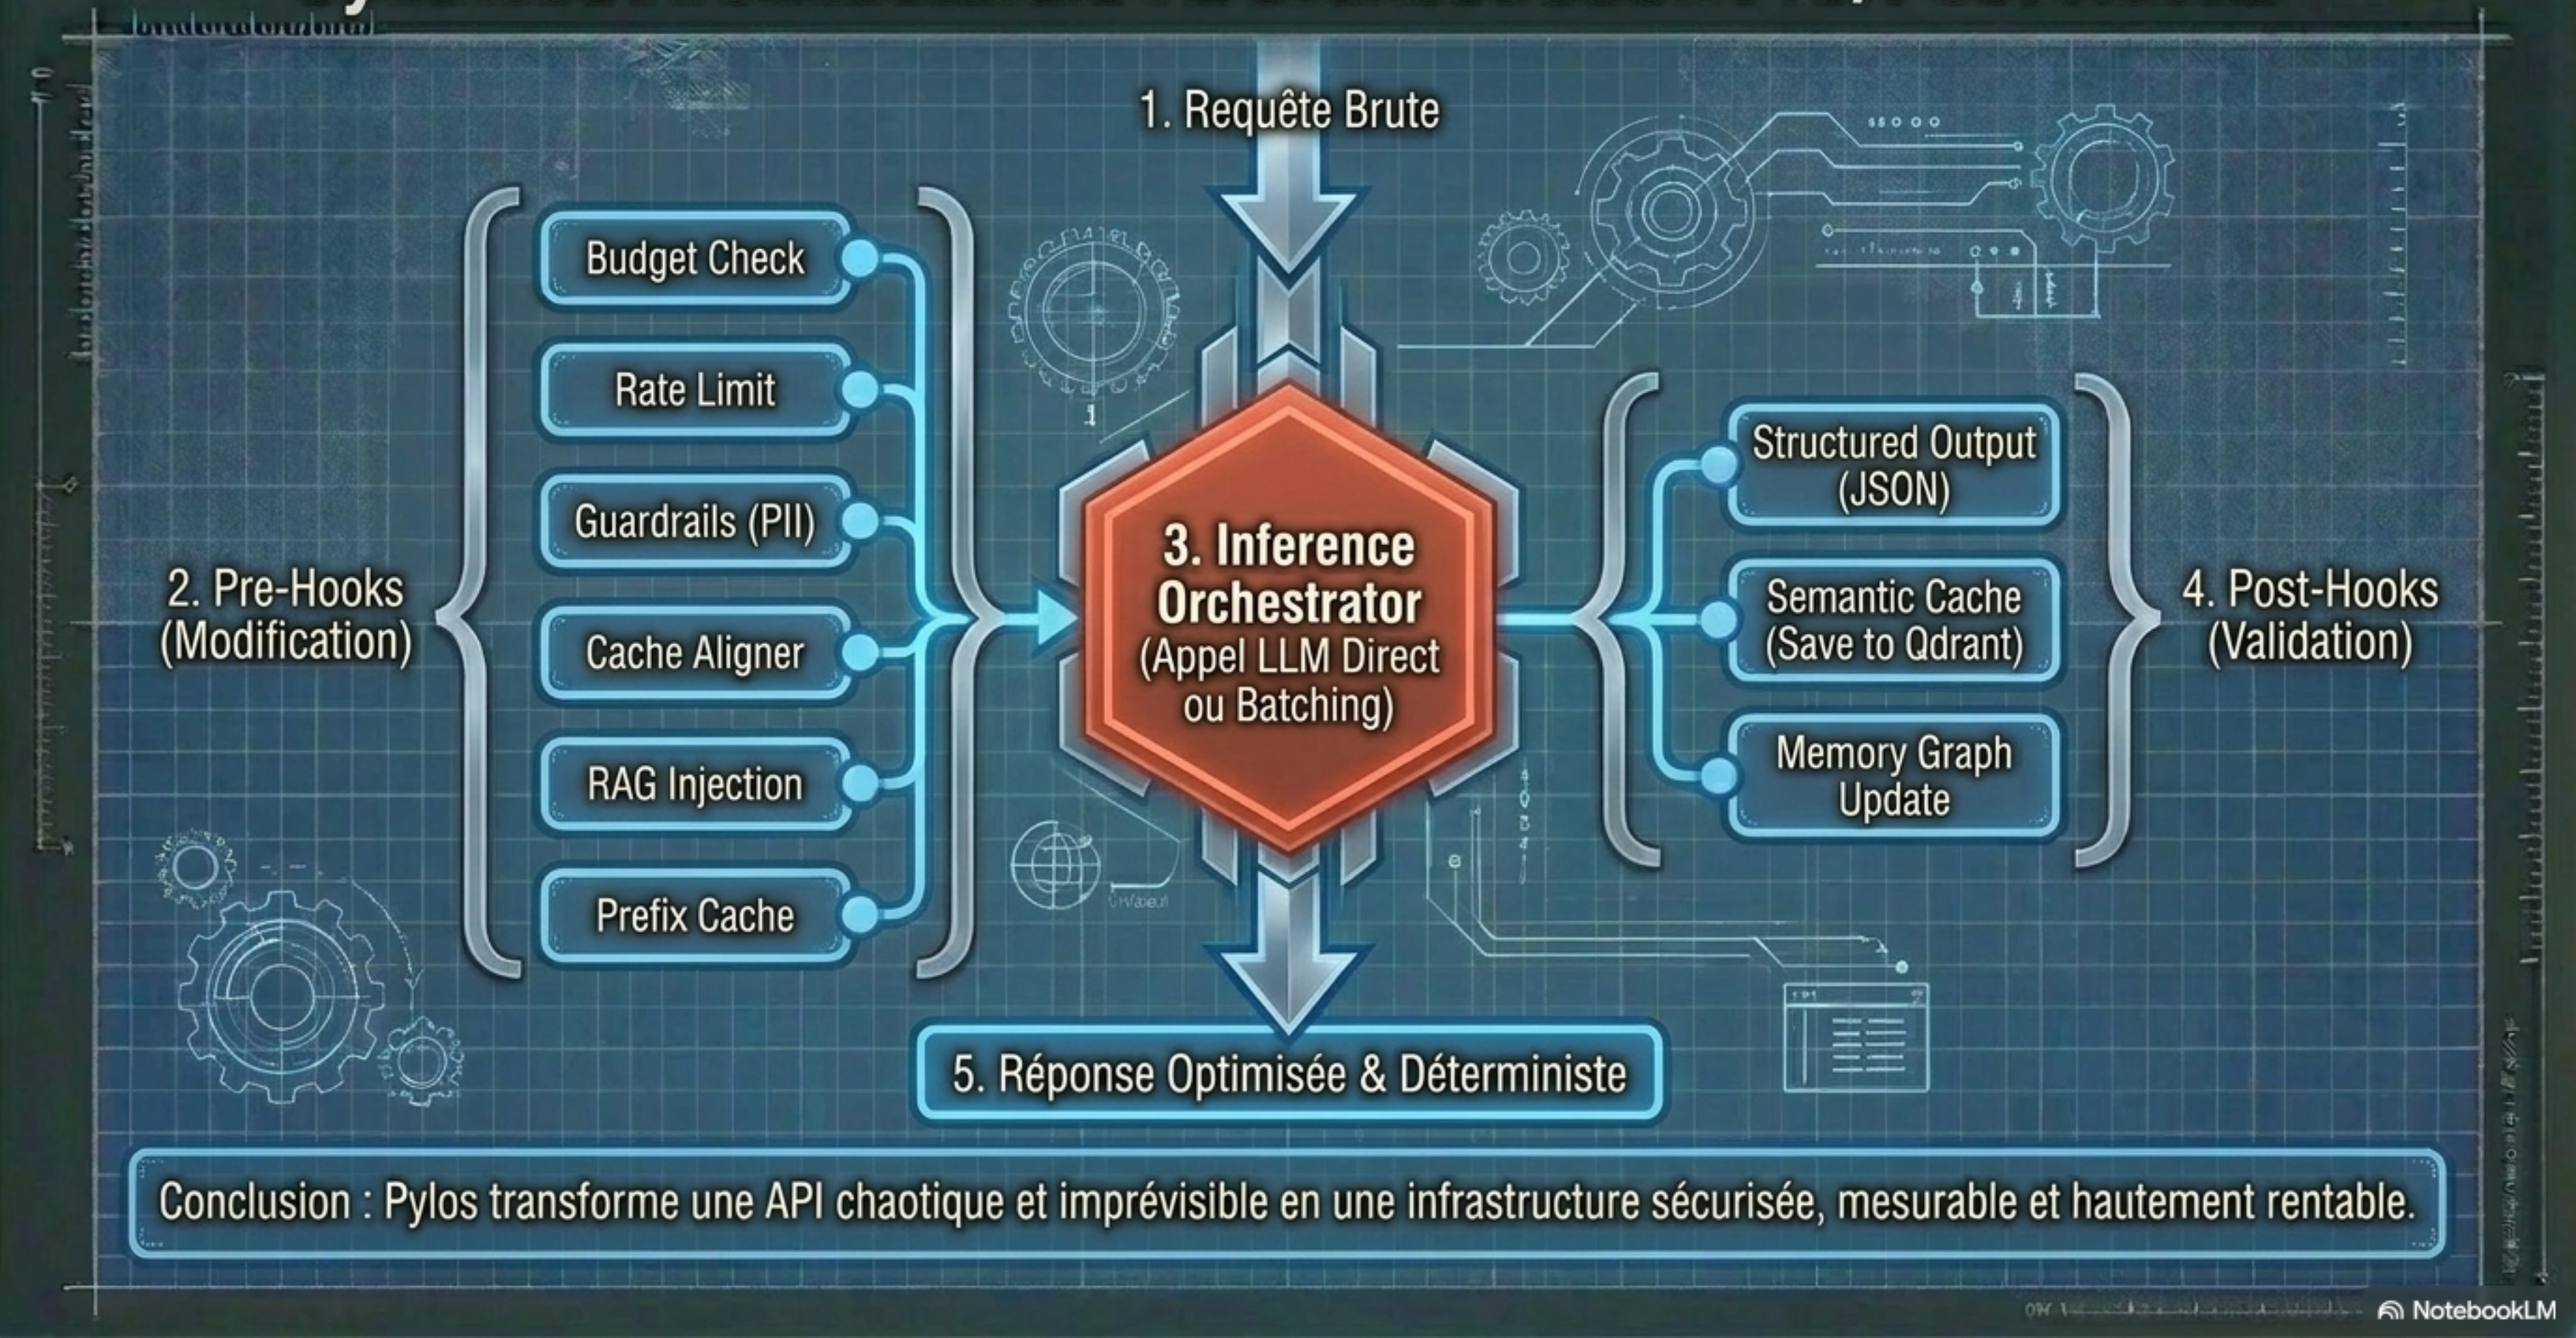



## Injection Sémantique Persistante (Memgraph)

Pylos ne stocke pas un simple historique textuel plat. Le pre-hook capture et modélise les relations sémantiques persistantes de l'utilisateur. À chaque nouvelle session, ce graphe de connaissances est injecté, offrant au LLM un contexte absolu sans répétition.

NotebookLM

# Synthèse Architecturale : L'Orchestration Pre/Post Hooks




Conclusion : Pylos transforme une API chaotique et imprévisible en une infrastructure sécurisée, mesurable et hautement rentable.

NotebookLM